Universität zu Köln

Philosophische Fakultät

Institut für Digital Humanities

Schwerpunktmodul 1: Seminar: Künstliche Intelligenz und die (digitale) Gesellschaft

Dozent: Prof. Dr. Nils Reiter

Wintersemester 25/26

Abgabedatum: 21.03.2026

Automatische Vorhersage von Metacritic-Nutzerbewertungen anhand von Rezensionstexten

Verfasser des Essays:

Niklas Halft

Matrikelnummer: 7396949

M.A.: Informationsverarbeitung

1. Semester

Hilgener Straße 7

51067 Köln

nhalft@smail.uni-koeln.de

Inhalt

Abstract 1
1. Einleitung 1
2. Verwandte Arbeiten 3
3. Methodik 4
3.1 Preprocessing 4
3.2 Transformer-Ansatz 6
3.3 Prompting 8
4. Ergebnisse 9
4.1 Transformer 10
4.2 Prompting 12
5. Fazit 16
6. Literaturverzeichnis 17
7. Selbstständigkeitserklärung 20
Anhang 21

Abstract

Bewertungssysteme für Videospiele stellen eine zentrale Informationsquelle sowohl für Spieler als auch für Entwickler dar und beeinflussen maßgeblich Kaufentscheidungen sowie die Weiterentwicklung von Spielen. In der vorliegenden Arbeit werden Nutzerbewertungen auf Metacritic anhand von Rezensionstexten in 5 Klassen (sehr schlecht, schlecht, durchschnittlich, gut, sehr gut) eingeteilt. Um die Vergleichbarkeit der Bewertungen zu gewährleisten, wurden nur Nutzerbewertungen von Spielen der Marke Nintendo miteinbezogen.

Es wurden zwei Ansätze miteinander verglichen. Zum einen wurde ein vortrainiertes Transformer-Modell finegetuned, wobei sowohl eine Datenbasis ohne als auch mit zusätzlichen Metadaten aus den Nutzerprofilen der Bewertenden auf *Metacritic* verwendet wurde. Zum anderen kam ein Large Language Model zum Einsatz, das auf Basis verschiedener Prompts Vorhersagen generierte. Der Transformer-Ansatz erzielte dabei einen F1-Score von 0,62 und einen Mean Average Error von 0,4875. Der Prompting-Ansatz lag bei einem F1-Score von 0,60 mit einem Mean Average Error von 0,4517. Zentrale Herausforderungen stellten dabei die unausgewogene Datenbasis und die mangelnde Datenverfügbarkeit dar. Die erzielten Ergebnisse können als Ausgangspunkt für weiterführende Forschungen dienen, um ein tieferes Verständnis des Videospielmarktes zu ermöglichen.

1. Einleitung

Der Videospielmarkt ist seit mehreren Jahrzehnten ein stetig wachsendes Feld, und ein Ende dieses Wachstums ist derzeit nicht absehbar (Statista 2025). Die Videospielbranche wird auch zukünftig an Relevanz gewinnen. Dadurch werden auch Bewertungsmöglichkeiten von Videospielen für eine größer werdende Personengruppe immer relevanter.

Auch für große Unternehmen der Gamingbranche spielen Bewertungen auf *Metacritic*[1] eine große Rolle. Laut Aussagen von CEOs werden Verkaufszahlen maßgeblich durch diese beeinflusst (Greenwood-Erickson et. al. 2013, 102, 108). Metacritic ist eine Website, auf der Filme, Serien, Musikalben und Videospiele bewertet werden können. Die Plattform wurde 2001 gegründet und 2022 von *Fandom*[2] übernommen (Bisbey 2019) (Weprin 2022).

Metacritic stellt zwei unterschiedliche Bewertungssysteme bereit: Zum einen bewerten Magazine oder Websites ein Spiel auf einer Skala von 0-100. Dies ist der sogenannte *Metascore*. Dabei existiert eine nicht offengelegte Gewichtung der Quellen, was von Experten scharf kritisiert wird (Spector 2013). Zum anderen existiert der *User Score*, bei dem Nutzer Bewertungen auf einer Skala von 0-10 abgeben können. Dieser entspricht dem Durchschnitt aller abgegebenen Nutzerbewertungen.

[1] https://www.metacritic.com
[2] https://www.fandom.com

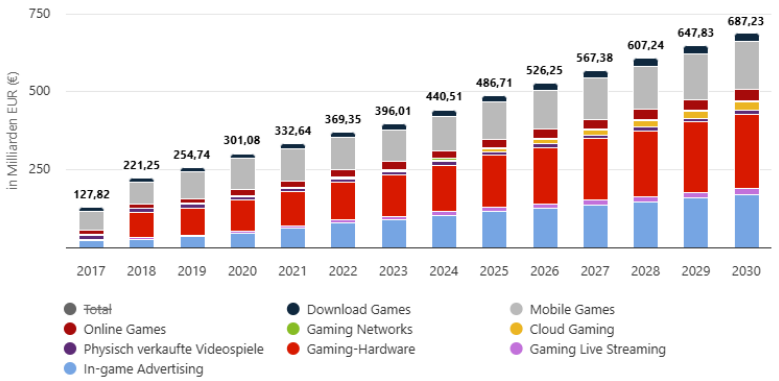

Abbildung 1: Entwicklung des Videospielmarkts und Prognose bis 2030. Quelle: Statista 2025.

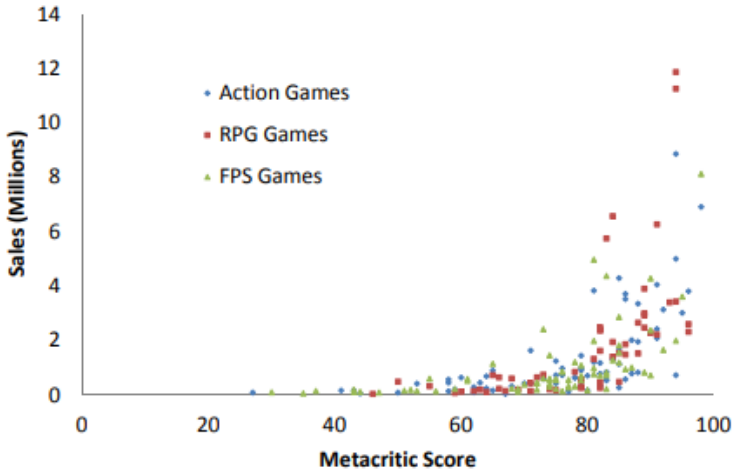

Abbildung 2: Metacritic Score von Spielen im Verhältnis zu deren Verkaufszahlen. Quelle: Greenwood-Erickson et. al. 2013, 108.

In der vorliegenden Arbeit wurde untersucht, wie präzise der User Score mit verschiedenen Klassifikationsmethoden vorhergesagt werden kann. Der Fokus liegt auf dem User Score, da dieser unvorhersehbarer und damit für Modelle schwerer vorherzusagen ist. Die Idee bestand darin zu testen, ob Modelle auch Muster in schwer kalkulierbaren Datensätzen finden können.

Dies ist auch für Unternehmen der Gaming-Branche sehr relevant, da ein besseres Verständnis der Einflussfaktoren auf Nutzerbewertungen höhere Einnahmen verspricht. Im Rahmen dieser Arbeit werden zwei Ansätze miteinander verglichen: Zum einen die Vorhersage durch ein finegetunetes Transformermodell. Zum anderen ein Prompting-Ansatz unter Verwendung eines Large Language Models aus dem Projekt *ki:connect.nrw*[3] des Bundeslandes Nordrhein-Westfalen.

Um die Vergleichbarkeit der Spiele zu gewährleisten, wurde sich bei der Auswahl auf Spiele der Marke Nintendo[4] beschränkt. Nintendo war hierfür gut geeignet, da der Konzern in die Videospielbranche ein bedeutender Akteur ist und deren Spiele konzeptionell ähnlich sind. Die Spiele sind zudem franchiseübergreifend für eine ähnliche Zielgruppe konzipiert und damit gut vergleichbar.

[3] https://chat.kiconnect.nrw/app
[4] www.nintendo.com

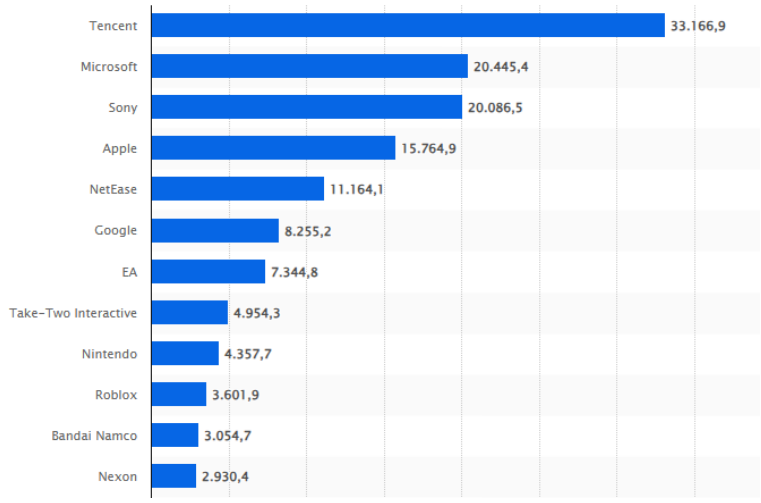

Abbildung 3: Führende Utnternehmen im Bereich Videospiele im Jahr 2024. Quelle: Newzoo 2025.

2. Verwandte Arbeiten

Die Vorhersage von Metascores ist bereits seit über einem Jahrzehnt Gegenstand wissenschaftlicher Untersuchungen.

Takatalo und Häkkinen (2014) versuchten den Metascore anhand subjektiver Spielerfahrungen aus einer Onlineumfrage vorherzusagen. Hierfür nutzten sie lineare Regression und kamen schlussendlich auf eine Accuracy von 75% (Takatalo und Häkkinen 2014, 442). Ein weiterer früher Ansatz von Yumusak et. al. (2016) zielte darauf ab anhand 7 verschiedener featurebasierter Ansätze das Rating von Musikalben vorherzusagen.

Weitere relevante Publikationen sind Santos et. al. (2024) und Coronado-Blázquez (2022). Santos et. al. (2024) analysierten Unterschiede zwischen Metascore- und Userscore-Bewertungen. Sie fanden dabei heraus, dass Nutzerbewertungen tendenziell stärker polarisieren, während die Bewertungen von Experten oft ausgeglichener sind (Santos et. al. 2024, 140). Zudem lässt sich beobachten, dass Nutzer meist im Laufe der Zeit tendenziell bessere Ratings vergeben (ebd.). Darüber hinaus sind Nutzerrezensionen in der Regel meist emotionaler und einfacher geschrieben (ebd.). Coronado-Blázquez (2022) beschäftigt sich in seinem Paper mit dem Phänomen des „Review Bombings“. Dieses tritt insbesondere bei Spielen auf, bei denen große Diskrepanzen zwischen Metascore und Userscore bestehen (Coronado-Blázquez 2022, 1). Dabei kommt es zu größeren Wellen negativer Bewertungen von Fans, ausgelöst durch politische, ökonomische oder kulturelle Entscheidungen von Publishern (Dutton et. al. 2011). Coronado-Blázquez (2022) konnte mit Hilfe eines NLP-basierten Machine Learning Modells und einem Datensatz von über 50000 User-Bewertungen „Review Bombing“ und „normale“ schlechte Bewertungen mit einer Accuracy von 0,88 unterscheiden. Metacritic reagierte 2020 auf dieses Phänomen und Bewertungen sind mittlerweile erst 36 Stunden nach Release des Spiels möglich (Heise 2020).

Neben der Vorhersage des Metascores existieren auch Ansätze zur Prognose des Userscores. Ramos et. al. (2022) versuchten den User Score von Filmen mit einer Kombination verschiedener lexikonbasierter Ansätze vorherzusagen. Dabei integrierten sie Metadaten als Features mit (Ramos et. al. 2022, 11). Sie nutzten einen großen Datensatz von 10000 Reviews und kamen auf einen Mean Average Error von 2,428 (Ramos et. al. 2022, 12, 14).

Eine wichtige Grundlage für die vorliegende Arbeit stellt die Studie von Zhou et al. (2024) dar. Diese kommt zum Schluss, dass Large Language Models zwar nicht die Leistungsfähigkeit menschlicher Gutachter bei der Bewertung von Rezensionen erreichen, jedoch insbesondere bei kürzeren Texten durchaus sinnvolle Vorhersagen liefern können (Zhou et. al. 2024, 9348).

Tan et. al. (2022) trainierten mehrere Modelle auf insgesamt 17543 User Reviews von Steam und Metacritic. Die Klassifikation erfolgte in 3 Kategorien: positiv, neutral und negativ (65). Zur Feature-Extraktion wurde *TF-IDF* eingesetzt, bevor verschiedene klassische Machine-Learning-Modelle evaluiert wurden (Tan et. al. 2022, 66). Wie in Tabelle 2 sichtbar erzielte der Support Vector Classifier dabei mit einem F1-Score von 0,91 die beste Performance (Tan et. al. 2022, 67).

Tabelle 1: Performance der Modelle von Tan et al. Quelle: Tan et. al. 2022, 67.

Model	Accuracy	Weighted Precision	Weighted Recall	Weighted F1-Score	Negative	Neutral	Positive	Status
SVC	89.7%	90.0%	89.7%	89.2%	89.7%	–	90.1%	**Accepted**
MLP	87.0%	87.1%	87.0%	86.7%	87.0%	–	87.0%	**Rejected**

Tabelle 2: Classification Report SVC von Tan et. al. Quelle: Tan et. al. 2022, 67.

Klasse	Precision	Recall	F1-Score	Support
negative	0.97	0.91	0.63	2044
neutral	0.91	0.87	0.89	2082
positive	0.87	0.96	0.91	2130
Accuracy			0.91	6256

Konkrete Vergleiche zwischen finegetuneten Transformeransätzen und LLM-Ansätzen zur Bewertung von Userscores auf Metacritic gibt es Stand März 2026 bislang nicht. Dazu gibt es bislang noch keine Ansätze, die sich bei der Vorhersage auf ein Videospielgenre festlegen.

3. Methodik

Im Folgenden gehe ich genauer auf den Ablauf und die Implementation meines Experiments ein.

3.1 Preprocessing

Der erste Schritt bestand darin, an einen Datensatz mit Metacritic-Reviews zu gelangen. Zwar existieren bereits einige Datensätze, diese waren jedoch entweder auf die Gesamtbewertung von Spielen ausgerichtet oder nicht öffentlich zugänglich[5][6]. Dazu waren diese nicht auf ein spezifisches Genre von vergleichbaren Spielen ausgerichtet. Zudem waren die verfügbaren Datensätze teilweise mehrere Jahre alt und somit für die Einbeziehung aktueller Spiele ungeeignet. Somit waren die Auswahlmöglichkeiten eher eingeschränkt.

Aus diesem Grund wurde entschieden, die benötigten Daten eigenständig zu erheben. Dazu wurde ein JavaScript-Skript *scraper.js* erstellt. In diesem wurden mithilfe der Web-Scraping Bibliothek *Puppeteer*[7] jeweils 120 Nutzerbewertungen aus 10 verschiedenen Spielen gesammelt. Dabei wurde auf eine ausgewogene Verteilung der Bewertungen geachtet: 40 Bewertungen mit einem Score unter 4, 40 Bewertungen im Bereich von 4 bis 7 sowie 40 Bewertungen über 7.

Die Auswahl der Spiele beschränkte sich nur auf Titel von Nintendo. Die Auswahl war dabei nicht sehr groß, da nur wenige Titel eine ausreichende Anzahl an Bewertungen in allen drei Kategorien aufwiesen. Viele Spiele waren dabei oft sehr positiv oder sehr negativ bewertet und somit fehlten oft neutrale oder

[5] https://github.com/rohinm12/Metacritic-Game-Reviews-Sentiment-Analyzer
[6] https://github.com/RichardCMason/Analyzing-Metacritic-Video-game-review-scores
[7] https://pptr.dev

Bewertungen des jeweils anderen Spektrums. Deshalb wurde im Laufe des Scrapingprozesses das Limit von 50 auf 40 reduziert.

Abbildung 4: Ausgewählte Spiele. Quelle: Collage der Bilder von Metacritic.

Auf diese Weise konnten insgesamt 1.200 Bewertungen gesammelt werden, bestehend aus jeweils 400 positiven, 400 neutralen und 400 negativen Rezensionen. Das Skript wurde auf Basis der Datenbasis zum Stand des 11.03.2026 ausgeführt.


```
{
  "reviews": [
    {
      "username": "kaylalicious",
      "rating": 9,
      "date": "Mar 2, 2026",
      "review": "this game is soooooo **** fire. every year or so they release so
    },
    {
      "username": "Dangusse",
      "rating": 7,
      "date": "Feb 24, 2026",
      "review": "this game was never finished, it has less features than any pre
    },
    {
      "username": "Ligers",
      "rating": 8,
      "date": "Feb 20, 2026",
      "review": "An excellent way to spend to your time if you just wanna relax.
    },
```


Abbildung 5: Ausschnitt aus der Datei der Reviews ohne Metadaten. Quelle: animal-crossing-new-horizons.json.

```
{
  "reviews": [
    {
      "username": "kaylalicious",
      "rating": 9,
      "date": "Mar 2, 2026",
      "review": "this game is soooooo **** fire. every year or so they release some engagement bait update and it works i
      "metadata": {
        "averageUserScore": 8.8,
        "games": "4",
        "scoreCounts": {
          "positive": 4,
          "neutral": 0,
          "negative": 0
        }
      }
    },
    {
      "username": "Dangusse",
      "rating": 7,
      "date": "Feb 24, 2026",
      "review": "this game was never finished, it has less features than any previously existing version of the game and
      "metadata": {
        "averageUserScore": 4.2,
        "games": "109",
        "scoreCounts": {
          "positive": 12,
          "neutral": 41,
          "negative": 56
        }
      }
    },
    {
      "username": "Ligers",
      "rating": 8,
      "date": "Feb 20, 2026",
      "review": "An excellent way to spend to your time if you just wanna relax. Loved all that you could do on your own
      "metadata": {
        "averageUserScore": 6.4,
```


Abbildung 6: Ausschnitt aus der Datei der Reviews mit Metadaten. Quelle animal-crossing-new-horizons_with_metadata.json.

Für jedes Spiel wurde eine separate JSON-Datei erzeugt. Dabei kann ausgewählt werden, ob die Bewertungen mit zusätzlichen Metadaten oder ohne diese extrahiert werden sollen. In der Variante ohne Metadaten wurden lediglich Basisinformationen wie Datum und Benutzername gespeichert. In der Variante mit Metadaten wurde zusätzlich auf die Profilseiten der Bewertenden zugegriffen, um weitere Informationen zu extrahieren, darunter der durchschnittliche Userscore, die Anzahl bewerteter Spiele sowie die Verteilung der vergebenen Bewertungen.

Nachdem dies für alle Spiele durchgeführt wurde, wurde mithilfe des Python-Skripts *attachJSON.py* verschiedene Preprocessing Schritte durchgeführt, damit die Modelle die Daten besser interpretieren können. Dazu wurden die einzelnen JSON-Dateien jeweils zu einem Gesamtdatensatz zusammengeführt, sodass sowohl für die Variante mit als auch ohne Metadaten jeweils ein Datensatz mit 1.200 Reviews zustande kommt.

3.2 Transformer-Ansatz

Nach den Vorbereitungsschritten wurde das Modell *roberta-base*[8] auf Basis des Datensatzes gefinetuned und trainiert. Im Vorfeld wurden mehrere alternative Modelle auf *HuggingFace* getestet, welche allesamt schlechter abgeschnitten hatten. Ziel war es, zwei separate Modelle zu entwickeln: eines auf Basis von Reviews ohne Metadaten sowie ein weiteres unter Einbeziehung zusätzlicher Metadaten. Dafür wurden zwei separate Python-Skripte erstellt (*train.py* und *train_metadata.py*). In diesen werden die Daten zunächst eingelesen und anschließend aufbereitet, wobei die Methode prepareData() die jeweiligen Inputdaten für die Modelle zurückgibt.

```
def prepareData(review):
        return f"""
        Date: {review['date']}
        Review: {review['review']}
        """
```

Abbildung 7: Code der Methode prepareData für das Trainieren des Modells ohne Metadaten. Quelle: train.py.

Das Modell wurde mit einer Trainingsgröße von 80% und einer Testgröße von 20% trainiert. Die Testdaten wurden anschließend in einer separaten JSON-Datei geschrieben, die in den Scripts *predict.py* und *predict_metadata.py* im weiteren Verlauf erneut aufgerufen wird. Anschließend wurde ein Tokenizer

[8] https://huggingface.co/FacebookAI/roberta-base

erstellt. Reviews, die die maximale Sequenzlänge von 512 Tokens überschreiten (ca. 5–10 % der Daten), wurden in mehrere Chunks aufgeteilt.

Die Umsetzung dieser Segmentierung unterschied sich je nach Datensatzvariante: In den Skripten mit Metadaten erfolgte die Aufteilung manuell über die Methode build_chunks_for_reviews(), da jedem Segment die Metadaten als Präfix vorangestellt wurden. Für die Variante ohne Metadaten konnte hingegen der Parameter return_overflowing_tokens genutzt werden, der automatisch überlappende Token-Sequenzen generiert (Hugging Face).

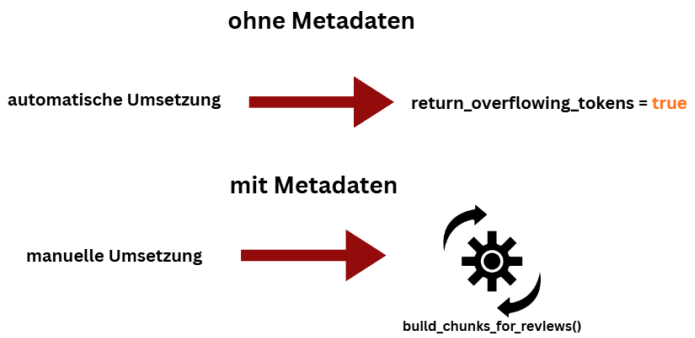

Abbildung 8: Umgang mit zu langen Reviews. Quelle: eigene Darstellung mit Canva.

Zunächst war der Plan, die Modelle das genaue Rating des Reviews im Bereich 0-10 vorhersagen zu lassen. Da sich dies jedoch als wenig präzise erwies und zusätzlich neben dem *Mean Absolute Error*[9], auch die klassischen Evaluationsmetriken aus dem *classification_report*[10] betrachtet werden sollten, wurde ein Mittelweg zwischen der klassischen Sentiment Analyse, also Einteilung in positiv, neutral und negativ und der genauen Klassifikation des User Scores eingeschlagen. Hierzu wurden die ursprünglichen Ratings mithilfe der Methode score_to_class in 5 Klassen von umgewandelt, die Werte von 0 bis 4 annehmen. Das Modell kann hierbei nur eine Klasse vorhersagen und nicht mehrere gleichzeitig.

```
def score_to_class(score):
score = int(score)
if score <= 1:
return 0
elif score <= 3:
return 1
elif score <= 6:
return 2
elif score <= 8:
return 3
else:
return 4
```

Abbildung 9: Code der Methode score_to_class. Quelle: train.py.

Tabelle 3: Bedeutung der verschiedenen Klassen. Quelle: eigene Darstellung.

Rating	Bedeutung
0	sehr schlecht
1	schlecht
2	durchschnittlich
3	gut
4	sehr gut

Somit waren die Klassen nicht gleichverteilt. Dies wäre aber mit der gewählten Aufteilung in 5 Klassen ohnehin schwer zu erreichen gewesen, da sonst noch weniger Trainingsdaten vorhanden gewesen wären, was das Modell qualitativ verschlechtert hätte. Aufgrund der unterschiedlichen Häufigkeit der Klassen wurden die Klassen je nach Häufigkeit unterschiedlich gewichtet. Um diese Gewichtung in den Trainer einzupflegen, musste die Methode compute_loss() der Trainerklasse durch eine veränderte Variante ersetzt werden.

[9] https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_absolute_error.html
[10] https://scikit-learn.org/stable/modules/generated/sklearn.metrics.classification_report.html

Im Skript *predict.py* wurde das trainierte Modell schlussendlich auf die Testdaten aus der zuvor erstellten JSON-Datei angewandt und es wurden die entsprechenden Evaluationsmetriken berechnet.

3.3 Prompting

Des Weiteren wurde noch ein LLM genutzt, welches durch das Projekt *KI:connect.nrw* bereitgestellt wurde. *KI:connect.nrw* ist ein Projekt des Bundeslandes Nordrhein-Westfalen, durch das Mitglieder von Hochschulen Zugang zu kommerziellen generativen KI-Modelle bekommen (RWTH Aachen 2026). Für die vorliegende Arbeit wurde dabei den Zugang der Universität zu Köln genutzt.

Zum Zeitpunkt der Nutzung war die Auswahl verfügbarer Modelle begrenzt. Die beste Performance erzielte das Modell *Openai GPT OSS 120B*. Zum Durchführen der Prediction wurde hierbei ein eigener API-Key benötigt.

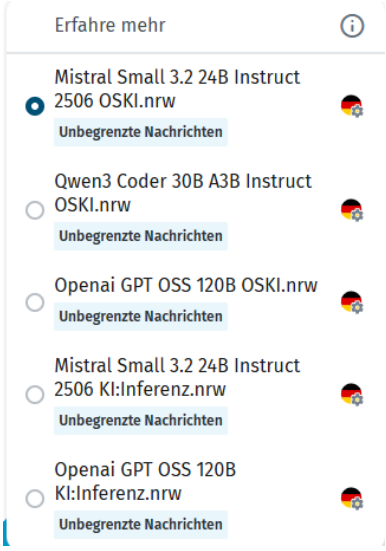

Abbildung 10: Auswahl der Modelle bei KI:connect.nrw. Quelle: KI:connect:nrw.

Analog zum Transformer-Ansatz wurde auch hier eine Umrechnung der ursprünglichen Ratings von einer Skala von 0–10 auf fünf Klassen vorgenommen. Zusätzlich bot der Prompting-Ansatz weitere Variationsmöglichkeiten: Neben der Integration von Metadaten in die Prompts konnte auch Few-Shot-Prompting eingesetzt werden, bei dem dem Modell zusätzlich zum Prompt Beispiele bereitgestellt werden. Dabei wurden schlussendlich 4 repräsentative Beispiele der Klassen 0, 3, 6 und 10 aus dem Datensatz ausgewählt und teilweise leicht vereinfacht. Diese Variante erzielte die besten Ergebnisse. Die *Temperature* erzielte mit dem Wert 0 die beste Performance, da zufällige Elemente nahezu ausgeschlossen werden und immer die wahrscheinlichste Antwort ausgewählt wird.

```
"You are an expert to predict the score of a game review. "
"You will be given a review and you have to predict the score of
the review on a scale from 0 to 10. Return the score as an int
number. "
"You should only output the score and nothing else."
```

Abbildung 11: Basisprompt für die Rolle des LLMs. Quelle: predict.py.

```
"You are an expert to predict the score of a game review. "
"You will be given a review and you have to predict the score of the
review on a scale from 0 to 10. Return the score as an int number. "
"You should only output the score and nothing else."
"Here are some examples:"
"Review: 'Worst game I ever played. Save your money and don't buy it.
Story is dull, combat is clunky as hell."
"True Class: 0"
"Just worse in every way than mk8deluxe. It's more expensive, has less
features, has worse tracks, and a useless open world. Looks pretty
though."
"True Class: 3"
"Review: 'Well this not the best Pokemon ever made, but it has clearly
lots of potential for fun, and is at least interesting, not gonna talk
about the dlc though.'"
"True Class: 6"
"Review: 'What an amazing game. One of the best Pokémon experiences I
have had.'"
"True Class: 10"
```

Abbildung 12: Basisprompt für die Rolle des LLMs mit few-shot-prompting.
Quelle: predict.py.

Der Basisprompt definiert die Aufgabe und fügt, wenn erwünscht, Beispiele hinzu. Der Nutzerprompt enthält dagegen das jeweilige Review, optional ergänzt durch Metadaten als Präfix. Dazu kann der Datensatz auf verschiedenen Trainingsdatengrößen über einen übergebenen Funktionsparameter getestet werden. Die vom Modell gegebenen Labels wurden per RegEx extrahiert und anschließend evaluiert.

4. Ergebnisse

Im Folgenden werde ich über die Ergebnisse, die diskutierbaren Punkte und die Schlussfolgerungen des Experiments sprechen.

Da die 5 Klassen jeweils unterschiedlich verteilt waren, bot sich eine Majority Baseline an. Für den Transformer-Ansatz standen 240 Test-Reviews zur Verfügung, während beim Prompting-Ansatz der vollständige Datensatz von 1.200 Reviews verwendet wurde. Beim Transformer-Ansatz war die Klasse 4 (sehr gut) mit 60 Instanzen am häufigsten vertreten, was einer Majority-Baseline von 0,25 entspricht. Beim Prompting-Ansatz stellte hingegen die Klasse 3 (gut) mit 276 Instanzen die größte Gruppe dar, was einer Baseline von 0,23 entspricht. Die Klassenverteilung war insgesamt dennoch relativ ausgeglichen, wobei lediglich die Klasse 1 (schlecht) deutlich unterrepräsentiert ist.

Tabelle 4: Tabelle der Baselines für den Transformer-Ansatz (links) und den Prompting-Ansatz (rechts). Quelle: eigene Darstellung.

Klasse	Precision	Recall	F1-Score	Support
0	0.00	0.00	0.00	57
1	0.00	0.00	0.00	29
2	0.00	0.00	0.00	48
3	0.00	0.00	0.00	46
4	0.25	1.00	0.40	60
Accuracy			**0.25**	**240**

Klasse	Precision	Recall	F1-Score	Support
0	0.00	0.00	0.00	254
1	0.00	0.00	0.00	146
2	0.00	0.00	0.00	266
3	0.23	1.00	0.37	276
4	0.00	0.00	0.00	258
Accuracy			**0.23**	**1200**

Zur Evaluation wurden verschiedene Metriken herangezogen, darunter Accuracy, Precision, Recall und F-Score. Dazu wurde bei beiden Ansätzen noch der M*ean Absolute Error (MAE)*[11] berechnet, welcher bei ordinalen Klassen die durchschnittliche Abweichung an Klassen des Modells anzeigt (Qi et. al. 2020, 2). Je niedriger dieser Wert, desto besser ist das Modell.

Zusätzlich wurden die Metriken spielweise berechnet, um festzustellen, ob es Unterschiede in der Verständlichkeit der Reviews der verschiedenen Spiele gab. Beim Prompting-Ansatz wurde darüber hinaus Few-Shot-Prompting mit 4 Beispielen eingesetzt. Zudem wurde die Modellperformance in Abhängigkeit von unterschiedlichen Trainingsdatensatzgrößen (200, 500, 800, 1.200 Reviews) untersucht.

4.1 Transformer

Tabelle 5: Vorhersageverteilung des Transformer-Ansatzes ohne Metadaten. Quelle: eigene Darstellung.

Klasse	**0**	**1**	**2**	**3**	**4**	**Gesamt**
Anzahl	69	24	41	44	62	240

Tabelle 6: Vorhersageverteilung des Transformer-Ansatzes mit Metadaten. Quelle: eigene Darstellung

Klasse	**0**	**1**	**2**	**3**	**4**	**Gesamt**
Anzahl	55	27	45	41	72	240

Wie in Tabelle 5 und 6 sichtbar, tendierten die Modelle dazu extreme Klassen vorherzusagen. Die Klassen 0 (sehr schlecht) und 4 (sehr gut) wurden hierbei mit 69/55 und 62/77 am häufigsten vorhergesagt. Dieses Verhalten spiegelt die in der Literatur beschriebene polarisierende Natur von Nutzerbewertungen wider (Santos et. al. 2024, 140). Klasse 1 wurde trotz Gewichtung der Klassen aufgrund des geringen Vorkommens in den Trainingsdaten am wenigsten vorhergesagt.

Tabelle 5: Tabelle des Classification Reports für den Transformer-Ansatz ohne Metadaten (links) und mit Metadaten (rechts). Quelle: eigene Darstellung.

Klasse	**Precision**	**Recall**	**F1-Score**
0	0.58	0.70	0.63
1	0.38	0.31	0.34
2	0.49	0.42	0.45
3	0.55	0.52	0.53
4	0.74	0.77	0.75
Accuracy			**0.58**
MAE: *0.5875*			

Klasse	**Precision**	**Recall**	**F1-Score**
0	0.69	0.67	0.68
1	0.41	0.38	0.39
2	0.49	0.46	0.47
3	0.59	0.52	0.55
4	0.76	0.92	0.83
Accuracy			**0.62**
MAE: *0.4875*			

Im Vergleich der Transformer-Ansätze zeigt das Modell mit Metadaten mit einem F1-Score von 0,62 eine leicht bessere Performance als das Modell ohne Metadaten (F1-Score: 0,58). Bei beiden Ansätzen ist die Performance unter anderem aufgrund der zuvor angesprochenen Vorhersageverteilung bei den Extremklassen 0 und 4 am besten. Das könnte auf Overfitting auf die beiden Extreme hindeuten. Der F1-Score der Klasse 4 im Modell mit Metadaten ist dabei besonders hoch.

Beide Ergebnisse der Modelle liegen deutlich über der Majority Baseline von 0,25. Wie in den Confusion Matrizen in Abbildung 13 und 14 sichtbar, hat das Modell ein gutes Gespür für die Tendenz des Reviews.

[11] https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_absolute_error.html

Das Modell liegt oft nur knapp daneben. Dies sieht man auch an den beiden niedrigen Mean Average Errors von 0,5875 beziehungsweise 0,4875.

Dennoch zeigen beide Modelle Schwierigkeiten bei der präzisen Klassifikation. Besonders Reviews der Klassen 1 oder 2 wurden von den Modellen als Klasse 0 identifiziert. Dieses Problem war besonders beim Modell ohne Metadaten deutlich ersichtlich. Mit dem Kontext des Nutzerprofils und dem tendenziell auf niedrige Bewertungen hindeutenden Bewertungsraster gelang dies dem Modell mit Metadaten besser.

Ein ähnliches Muster zeigt sich am oberen Ende der Skala. Viele Reviews der Klasse 4 werden vom Modell ohne Metadaten als Klasse 3 klassifiziert. Zudem weisen Reviews der Klasse 2 bei beiden Modellen eine breite Spannweite auf und werden über alle Klassen hinweg vorhergesagt.

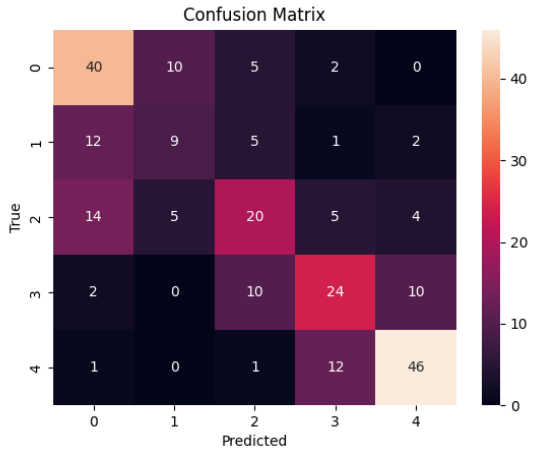

Abbildung 13: Confusion Matrix des Transformer-Ansatzes ohne Metadaten. Quelle: eigene Darstellung.

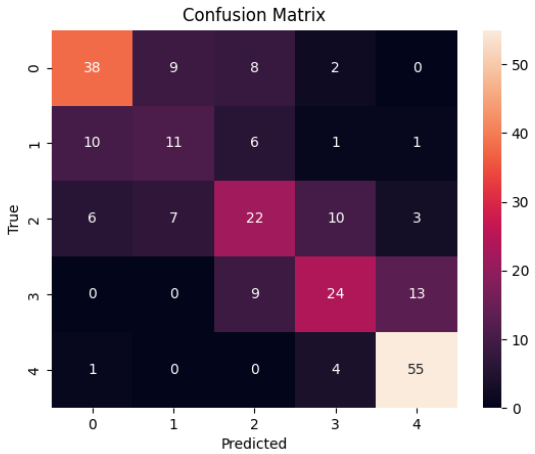

Abbildung 14: Confusion Matrix des Transformer-Ansatzes mit Metadaten. Quelle: eigene Darstellung.

Dies hat mehrere Gründe. Zum einen spielt die bereits erwähnte Emotionalität und Polarisierung von Nutzerbewertungen eine Rolle.


```
"username": "Anatoma",
"rating": 4,
"date": "Oct 18, 2025",
"game": "pokemon-legends-z-a",
"review": "If i had to make a list of the worst pokemon games ever made, this would be the second one right after sword and shield base game"
```


Abbildung 15: Beispiel für eine Polarisierende Bewertung mit gemäßigtem Rating. Quelle: all_without_metadata.json.

Dazu ist der Datensatz längentechnisch unausgewogen. Während einige Reviews eine Länge von über 1000 Tokens aufweisen, bestehen andere kurze Reviews aus 2-3 Wörtern. Dies erschwert das Lernen konsistenter Muster des Modells. Eine Filterung nach Textlänge wäre zwar möglich gewesen, hätte jedoch die ohnehin begrenzte Datenmenge weiter reduziert und wurde daher schlussendlich nicht angewandt.

Ein Hauptgrund sind dazu die verschiedenen Klassifikationsarten, nach denen der Score vergeben wird. Während beim Scraping bewusst eine Einteilung in 40 positive, 40 neutrale und 40 negative Reviews durchgeführt wurde, sollte das Modell nach der Umrechnung des Scores die exakte Klasse von 0-4 vorhersagen. Das ist eine unnötige Komplizierung des Ablaufs. Eine klassische Sentiment-Analyse mit drei Klassen hätte vermutlich eine deutlich bessere Performance erzielen können. Ziel dieser Arbeit war jedoch einen Kompromiss zwischen der zunächst geplanten exakten Vorhersage des Scores von 0-10 und klassischer Sentiment Analyse zu finden. Vor diesem Hintergrund sind die erzielten Ergebnisse dennoch als solide zu bewerten. Für eine praktische Anwendung wäre jedoch entweder eine Reduktion auf drei Klassen oder die Nutzung eines größeren Datensatzes sinnvoll. Dafür müsste man eventuell auf die Vergleichbarkeit der Spiele verzichten.

Das Modell ohne Metadaten wurde über 10 Epochen trainiert. Das Modell erreichte beim Training über 20 Epochen einen leicht verbesserten F1-Score von 0,64. Da das Modell allerdings über 30 Gigabyte groß war und dies für den Endnutzer nicht praktikabel ist, wurde sich schlussendlich für die leichtgewichtigere Variante entschieden.

Die spielbezogenen Auswertungen sind beim Transformer-Asnatz teilweise nur eingeschränkt aussagekräftig, da sie auf kleinen Stichproben von 20-30 Reviews basieren. Die höchsten F1-Scores erreicht das Modell ohne Metadaten hier bei *Paper Mario: Sticker Star* und *Mario Kart World* (0,67) und den niedrigsten bei *The Legend of Zelda: Tears of the Kingdom* (0,50). Interessanterweise erreicht das Modell mit Metadaten für *The Legend of Zelda: Tears of the Kingdom* mit identischen Reviews einen deutlich besseren F1-Score von 0,65. Die höchsten Werte liegen beim Modell mit Metadaten bei *Animal Crossing: New Horizons* (0,68) und *Mario Kart World* (0,75), während sich der F1-Score von *Paper Mario: Sticker Star* mit 0,67 über die beiden Modelle gar nicht verändert.

Tabelle 6: Tabelle des Classification Reports für das Spiel The Legend of Zelda: Tears of the Kingdom für den Transformer-Ansatz ohne Metadaten (links) und mit Metadaten (rechts). Quelle: eigene Darstellung.

Klasse	Precision	Recall	F1-Score
0	0.40	0.40	0.40
1	0.00	0.00	0.00
2	0.50	0.40	0.44
3	0.00	0.00	0.00
4	0.86	0.86	0.86
Accuracy			**0.50**

Klasse	Precision	Recall	F1-Score
0	0.62	1.00	0.77
1	1.00	0.33	0.50
2	1.00	0.20	0.33
3	0.00	0.00	0.00
4	1.00	0.86	0.92
Accuracy			**0.65**

4.2 Prompting

Tabelle 7: Vorhersageverteilung des Prompting-Ansatzes ohne Metadaten. Quelle: eigene Darstellung.

Klasse	0	1	2	3	4	Gesamt
Anzahl	106	352	245	226	271	1200

Tabelle 8: Vorhersageverteilung des Prompting-Ansatzes mit Metadaten Quelle: eigene Darstellung.

Klasse	0	1	2	3	4	Gesamt
Anzahl	182	329	227	260	202	1200

Während der Transformer-Ansatz dazu tendierte Extreme vorherzusagen, zeigt sich beim Prompting-Ansatz eine gegenteilige Entwicklung. Insbesondere beim Einsatz von Metadaten werden extreme Klassen deutlich seltener vorhergesagt. Stattdessen vergab das Modell viele Vorhersagen der in den Realdaten kaum repräsentierten Klasse 1. Dies liegt vor allem daran, dass das Modell nicht trainiert wurde und somit keine direkte Anpassung an die Trainingsdaten geschah.

Tabelle 9: Tabelle des Classification Reports für den Prompting-Ansatz ohne Metadaten (links) und mit Metadaten (rechts). Quelle: eigene Darstellung.

Klasse	Precision	Recall	F1-Score
0	0.70	0.50	0.59
1	0.27	0.60	0.37
2	0.51	0.44	0.47
3	0.58	0.55	0.57
4	0.84	0.66	0.74
Accuracy			**0.55**
MAE: *0.5242*			

Klasse	Precision	Recall	F1-Score
0	0.90	0.37	0.53
1	0.32	0.77	0.45
2	0.58	0.53	0.56
3	0.67	0.55	0.60
4	0.81	0.85	0.83
Accuracy			**0.60**
MAE: *0.4517*			

Die Prompting-Ansätze erreichten mit F1-Scores von 0,55 (ohne Metadaten) und 0.60 (mit Metadaten) eine leicht geringere Gesamtperformance. Auffällig ist erneut die schwache Performance der Klasse 1, wobei das im Vergleich zu den Transformer-Ansätzen nicht am schlechteren Recall, sondern an der deutlich schlechteren Precision lag. Das Modell wies also viele Reviews der Klasse 1 zu. Im Unterschied zum Transformer-Ansatz ist dies jedoch weniger auf einen niedrigen Recall, sondern vielmehr auf eine geringe Precision zurückzuführen. Dies lag vermutlich auch daran, dass beim Prompting-Ansatz die Klassen nicht zuvor gewichtet wurden. Dennoch sind die Ergebnisse insgesamt nicht signifikant schlechter als die der Transformer-Ansätze, was sich vor allem an der durchgängig über beide Modelle besseren Klassifikation von Klasse 1 bis 3 zeigt. Der Mean Average Error bewegt sich bei beiden Ansätzen mit 0,5242 (ohne Metadaten) und 0,4517 (mit Metadaten) in einem besseren Bereich, als der der Transformer-Modelle und zeigt, dass das Modell bei seinen Vorhersagen oft nur knapp daneben lag.

Dies zeigt sich auch bei den beiden Confusion Matrizen, die in Abbildungen 16 und 17 zu sehen sind. Auch hier zeigt sich, dass Reviews der Klasse 4 häufig als Klasse 3 klassifiziert werden sowie der Trend, dass sich dies beim Metadaten-Ansatz stark bessert. Auffällig ist, dass die Spannweite der Vorhersagen von Reviews der Klasse 2 abnimmt und das Modell durchschnittliche Reviews besser einschätzen kann. Dafür hat das Modell größere Probleme damit, die Reviews der Klasse 0 einzuordnen. Das Modell klassifiziert viele Reviews der Klasse 0 als Klasse 1. Ein ähnliches Problem zeigt sich bei Klasse 2, deren Reviews häufig als Klasse 1 klassifiziert werden. Man kann insgesamt den Schluss ziehen, dass das Modell deutlich weniger zu Extremen neigt als die Modelle des Transformer-Ansatzes, was auf die fehlende Anpassung an die Trainingsdaten zurückzuführen ist.

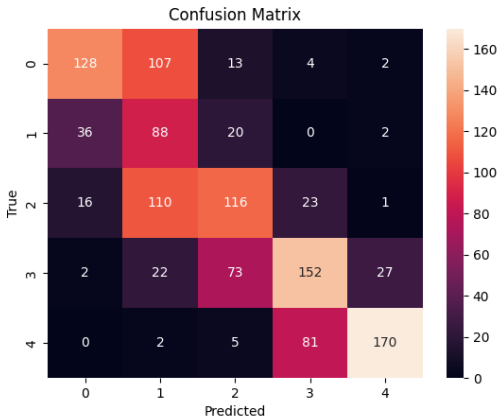

Abbildung 16: Confusion Matrix des Prompting-Ansatzes ohne Metadaten. Quelle: eigene Darstellung.

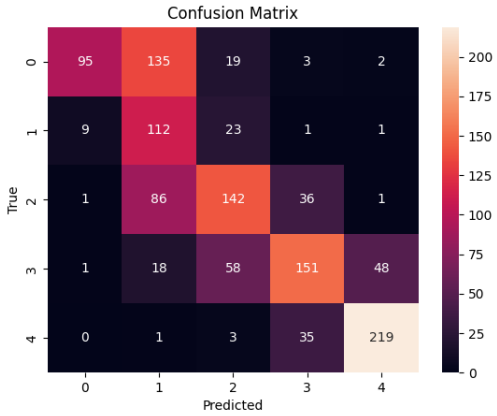

Abbildung 17: Confusion Matrix des Prompting-Ansatzes mit Metadaten. Quelle: eigene Darstellung.

Das Few-Shot-Prompting blieb hinter den Erwartungen zurück. Mit F1-Scores von 0,53 (ohne Metadaten) und 0,60 (mit Metadaten) war dieses tendenziell sogar schwächer. Die Verschlechterung betraf aber ausschließlich Klasse 4, deren F1-Score von 0,74 auf 0,68 sank. Der Mean Average Error war bei beiden Modellen ebenfalls leicht schwächer. Es wurden mehrere Prompts mit unterschiedlichen Beispielen getestet, die teilweise noch geringere Leistungen erzielten. Vermutlich wäre im Prozess noch Potential für Verbesserungen gewesen. Andererseits ist der Datensatz auch nicht einfach durch wenige Beispiele repräsentierbar, da dieser sehr divers ist.

Darüber hinaus wurde die Modellleistung in Abhängigkeit von der Datensatzgröße untersucht. Hier zeichneten sich unterschiedliche Tendenzen ab. Während der Ansatz ohne Metadaten mit steigender Datensatzgröße eine leichte Verbesserung aufzeigte, passierte beim Ansatz mit Metadaten das Gegenteil. Eine mögliche Erklärung ist, dass die mitgegebenen Metadaten bei den kleineren Datensätzen besonders gut zu den Reviews passen.

Tabelle 12: F1-Score im Verhältnis zur Datensatzgröße beim Prompting-Ansatz ohne Metadaten

Größe der Daten (n)	F1-Score
200	0.53
500	0.53
800	0.53
1200	0.55

Tabelle 13: F1-Score im Verhältnis zur Datensatzgröße beim Prompting-Ansatz mit Metadaten.

Größe der Daten (n)	F1-Score
200	0.65
500	0.61
800	0.60
1200	0.60

Die Analyse auf Spielebene war beim Prompting-Ansatz aufgrund der größeren Datenbasis deutlich aussagekräftiger.

Tabelle 10: F1-Score pro Spiel bei den Prompting-Ansätzen ohne Metadaten (links) und mit Metadaten (rechts). Quelle: eigene Darstellung.

Spiel	F1-Score
Mario Kart World	0.54
Animal Crossing: New Horizons	0.56
The Legend of Zelda: Breath of the Wild	0.54
Pokemon Legends: Z-A	0.53
Nintendo Switch Sports	0.47
The Legend of Zelda: Tears of the Kingdom	0.52
Pokemon Scarlet	0.54
Paper Mario: Sticker Star	0.58
Super Mario Party	0.60
Super Smash Bros. Ultimate	0.56

Spiel	F1-Score
Mario Kart World	0.61
Animal Crossing: New Horizons	0.61
The Legend of Zelda: Breath of the Wild	0.68
Pokemon Legends: Z-A	0.57
Nintendo Switch Sports	0.57
The Legend of Zelda: Tears of the Kingdom	0.62
Pokemon Scarlet	0.55
Paper Mario: Sticker Star	0.55
Super Mario Party	0.57
Super Smash Bros. Ultimate	0.67

In Tabelle 14 fällt auf, dass mit Ausnahme von *Paper Mario: Sticker Star* und *Super Mario Party* alle Spiele vom Einsatz von Metadaten profitieren. Generell scheint das Modell mit Metadaten mit Reviews von Pokemonspielen größere Schwierigkeiten zu haben als mit Spielen der *The Legend of Zelda*-Reihe. Dies deutet darauf hin, dass der Kontext der Metadaten bei bestimmten Spieltypen hilfreicher für das Modell ist.

Ein mit 0.11 verhältnismäßig großer Leistungsunterschied ist bei *Super Smash Bros. Ultimate* zu beobachten. Es könnte sein, dass bei laut dem Userscore Spiele eher mittelmäßigen oder unterdurchschnittlichen Spielen wie *Paper Mario: Sticker Star*, *Super Mario Party* oder die Pokemonspiele die Metadaten eher ein Hindernis für die Bewertung darstellen. Dies könnte daran liegen, dass diese Spiele auch von Nutzern mit sonst positiven Bewertungsmustern schlecht bewertet werden. Dies könnte das Modell potenziell verwirren. Daraus könnte sich ableiten lassen, dass der Einsatz von Metadaten nur bei ausschließlich positiv bewertenden Spielen sinnvoll ist.

5. Fazit

Die Ergebnisse dieser Arbeit zeigen, dass Nutzerbewertungen auf Metacritic für die Modelle schwer zu durchschauende Muster aufweisen. Insbesondere die starke Polarisierung und emotionale Ausdrucksweise vieler Reviews erschweren eine präzise Vorhersage.

Die Transformer-Modelle neigen dazu, extreme Klassen überproportional häufig vorherzusagen, während der Prompting-Ansatz eine gegenteilige Tendenz zeigt und insbesondere die Klasse 1 überbewertet. Die Ansätze bewegten sich insgesamt auf einem ähnlichen Niveau, wobei der Transformer-Ansatz etwas besser abschnitt.

Es ist anzunehmen, dass eine klassische Sentiment-Analyse mit drei Klassen zu besseren Ergebnissen geführt hätte. Ziel dieser Arbeit war jedoch bewusst ein Kompromiss zwischen der genauen Bewertung des Userscores und klassischer Sentiment Analyse. Vor diesem Hintergrund sind die erzielten Ergebnisse als zufriedenstellend zu bewerten, da beide Ansätze die jeweiligen Baselines deutlich übertreffen.

Der Ansatz Spiele aus einem ähnlichen Genre auszuwählen, wurde bei Metacritic Bewertungen bislang noch nicht verfolgt und könnte ein spannender Ausgangspunkt für weitere Forschung sein. Abschließend lässt sich festhalten, dass Metacritic-Scores trotz berechtigter Kritik weiterhin ein relevanter Indikator für den wirtschaftlichen Erfolg und die öffentliche Wahrnehmung von Videospielen bleiben dürften. Große Unternehmen der Gamingbranche werden daher in Zukunft weitere Bemühungen aufstellen, um die Indikatoren einer guten Metacritic Bewertung in Erfahrung zu bringen.

6. Literaturverzeichnis

Bisbey, Bruce. 2019. (4) WHAT IS METACRITIC? (In the Entertainment industry.) | LinkedIn. https://www.linkedin.com/pulse/what-metacritic-entertainment-industry-bruce-bisbey/ (zugegriffen: 19. März 2026).

Coronado-Blázquez, Javier. 2024. A NLP Approach to „Review Bombing“ in Metacritic PC Videogames User Ratings. arXiv, 10. Mai. doi:10.48550/arXiv.2405.06306, http://arxiv.org/abs/2405.06306 (zugegriffen: 18. März 2026).

Dutton, Nathan, Mia Consalvo und Todd Harper. 2011. Digital pitchforks and virtual torches: Fan responses to the Mass Effect news debacle. *Convergence: The International Journal of Research into New Media Technologies* 17, Nr. 3 (August): 287–305. doi:10.1177/1354856511407802 .

Fandom. 2026. *Fandom*. 16. März. https://www.fandom.com (zugegriffen: 19. März 2026).

Fandom 2026. Movie Reviews, TV Reviews, Game Reviews, and Music Reviews - Metacritic. https://www.metacritic.com/ (zugegriffen: 21. März 2026).

Greenwood-Ericksen, Adams, Scott R. Poorman und Roy Papp. 2013. On the Validity of Metacritic in Assessing Game Value. *Eludamos: Journal for Computer Game Culture* 7, Nr. 1 (16. Dezember): 101–127. doi:10.7557/23.6150, .

Heise. 2020. „Review Bombing“: Nutzer-Reviews auf Metacritic nun erst 36 Stunden nach Release. *heise online*. 21. Juli. https://www.heise.de/news/Review-Bombing-Nutzer-Reviews-auf-Metacritic-nun-erst-36-Stunden-nach-Release-4848742.html (zugegriffen: 18. März 2026).

HuggingFace. 2024. FacebookAI/roberta-base · Hugging Face. 11. März. https://huggingface.co/FacebookAI/roberta-base (zugegriffen: 19. März 2026).

HuggingFace. Tokenizer · Hugging Face. https://huggingface.co/docs/transformers/main_classes/tokenizer (zugegriffen: 19. März 2026).

Mehta, Rohin Manish. 2021. rohinm12/Metacritic-Game-Reviews-Sentiment-Analyzer. Jupyter Notebook. 22. April. https://github.com/rohinm12/Metacritic-Game-Reviews-Sentiment-Analyzer (zugegriffen: 19. März 2026).

Newzoo. 2025. Videospiele - Top-Unternehmen nach Umsatz 2024. *Statista*. https://de.statista.com/statistik/daten/studie/194749/umfrage/die-10-groessten-game-publisher-weltweit/ (zugegriffen: 19. März 2026).

Nintendo. Offizielle Nintendo Deutschland-Seite. *Nintendo of Europe SE*. https://www.nintendo.com/de-de/ (zugegriffen: 19. März 2026).

PngAAA. Metacritic - 96 Is Metacritic Logo Png,The Last Of Us Logo Png - free transparent png images - pngaaa.com. https://www.pngaaa.com/detail/2540447 (zugegriffen: 18. März 2026).

Puppeteer. Puppeteer. https://pptr.dev/ (zugegriffen: 19. März 2026).

Qi, Jun, Jun Du, Sabato Marco Siniscalchi, Xiaoli Ma und Chin-Hui Lee. 2020. On Mean Absolute Error for Deep Neural Network Based Vector-to-Vector Regression. *IEEE Signal Processing Letters* 27: 1485–1489. doi:10.1109/LSP.2020.3016837, .

Ramos, João, Diogo Apóstolo und Hugo Gonçalo Oliveira. 2022. Movie Rating Prediction using Sentiment Features. In: *Conference Proceedings: Language Resources and Evaluation Conference (LREC 2022)*, 209–216. Marseille: 24. Juni. https://aclanthology.org/2022.salld-1.3/.

RichardCMason. 2019. RichardCMason/Analyzing-Metacritic-Video-game-review-scores. Jupyter Notebook. 24. Oktober. https://github.com/RichardCMason/Analyzing-Metacritic-Video-game-review-scores (zugegriffen: 19. März 2026).

RWTH Aachen. 2026. | KI:connect.nrw | Center für Lehr- und Lernservices | RWTH Aachen University | DE. https://cls.rwth-aachen.de/cms/cls/services-und-projekte/~bliovm/ki-connect-nrw/ (zugegriffen: 19. März 2026).

Santos, Tiago, Florian Lemmerich, Markus Strohmaier und Denis Helic. 2019. What's in a Review: Discrepancies Between Expert and Amateur Reviews of Video Games on Metacritic. *Proceedings of the ACM on Human-Computer Interaction* 3, Nr. CSCW (7. November): 1–22. doi:10.1145/3359242, .

Scikit-Learn. mean_absolute_error. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_absolute_error.html (zugegriffen: 19. März 2026).

Spector, Warren. 2013. Defining Success: Why Metacritic Should Be Irrelevant. *GamesIndustry.biz*. 13. Mai. https://www.gamesindustry.biz/defining-success-why-metacritic-should-be-irrelevant (zugegriffen: 19. März 2026).

Statista. 2025. Videospiele - Weltweit | Statista Marktprognose. *Statista*. https://de.statista.com/outlook/amo/medien/videospiele/weltweit (zugegriffen: 19. März 2026).

Takatalo, Jari M.E. und Jukka P. Häkkinen. 2014. Predicting the metascore with a subjective user experience data. In: *Proceedings of the first ACM SIGCHI annual symposium on Computer-human interaction in play*, 441–442. Toronto Ontario Canada: ACM, 19. Oktober. doi:10.1145/2658537.2661299, https://dl.acm.org/doi/10.1145/2658537.2661299 (zugegriffen: 18. März 2026).

Tan, Jie Ying, Andy Sai Kit Chow und Chi Wee Tan. 2022. A Comparative Study of Machine Learning Algorithms for Sentiment Analysis of Game Reviews. *The Journal of The Institution of Engineers, Malaysia* 82, Nr. 3 (24. November). doi:10.54552/v82i3.101, https://iemjournal.com.my/index.php/iem/article/view/101 (zugegriffen: 18. März 2026).

Universität zu Köln. UzKGPT. https://chat.kiconnect.nrw/app (zugegriffen: 19. März 2026).

Weprin, Alex. 2022. TV Guide, Metacritic, GameSpot Acquired by Fandom in $55M Deal With Red Ventures. *The Hollywood Reporter*. 3. Oktober. https://www.hollywoodreporter.com/business/digital/tv-guide-metacritic-gamespot-acquisition-fandom-1235231819/ (zugegriffen: 19. März 2026).

Yumusak, Semih, Emir Munoz, Pasquale Minervini, Erdogan Dogdu und Halife Kodaz. 2016. A Hybrid Method for Rating Prediction Using Linked Data Features and Text Reviews. KTO Karatay University, Konya, Turkey. Doi: https://doi.org/10.13025/21369.

Zhou, Ruiyang, Lu Chen, und Kai Yu. 2024. Is LLM a Reliable Reviewer? A Comprehensive Evaluation of LLM on Automatic Paper Reviewing Tasks. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pages 9340–9351, Torino, Italia. ELRA and ICCL.

7. Selbstständigkeitserklärung

Hiermit versichere ich, dass ich diese Hausarbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Die Stellen meiner Arbeit, die dem Wortlaut oder dem Sinn nach anderen Werken und Quellen, einschließlich Quellen aus dem Internet, entnommen sind, habe ich in jedem Fall unter Angabe der Quelle als Entlehnung kenntlich gemacht. Dasselbe gilt sinngemäß für Tabellen, Karten und Abbildungen. Diese Arbeit habe ich in gleicher oder ähnlicher Form oder auszugsweise nicht im Rahmen einer anderen Prüfung eingereicht.

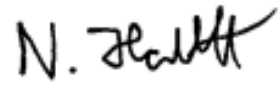

Niklas Halft, Köln, 20.03.2026

Anhang

1. Transformer

1.1 Ohne Metadaten

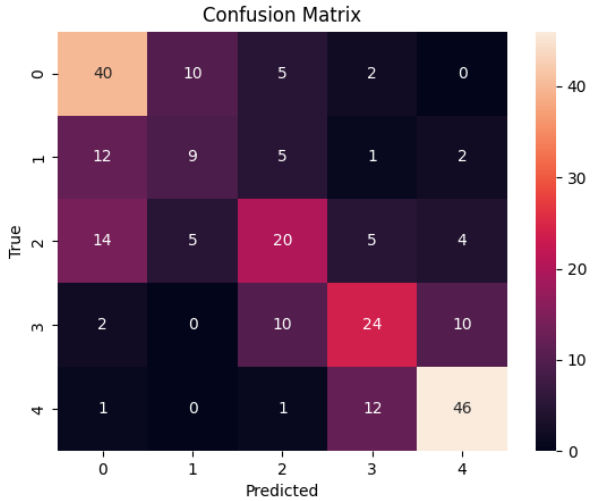

Vorhersageverteilung

Klasse	0	1	2	3	4	Gesamt
Anzahl	69	24	41	44	62	240

Gesamtergebnis

Klasse	Precision	Recall	F1-Score	Support
0	0.58	0.70	0.63	57
1	0.38	0.31	0.34	29
2	0.49	0.42	0.45	48
3	0.55	0.52	0.53	46
4	0.74	0.77	0.75	60
Accuracy			**0.58**	**240**
Macro Avg	0.55	0.54	0.54	240
Weighted Avg	0.57	0.58	0.57	240
MAE: *0.5875*				

Majority Baseline

Klasse	Precision	Recall	F1-Score	Support
0	0.00	0.00	0.00	57
1	0.00	0.00	0.00	29
2	0.00	0.00	0.00	48
3	0.00	0.00	0.00	46
4	0.25	1.00	0.40	60
Accuracy			**0.25**	**240**

Ergebnisse je Spiel

The Legend of Zelda: Tears of the Kingdom

Klasse	Precision	Recall	F1-Score	Support
0	0.40	0.40	0.40	5
1	0.00	0.00	0.00	3
2	0.50	0.40	0.44	5
3	0.00	0.00	0.00	0
4	0.86	0.86	0.86	7
Accuracy			**0.50**	**20**
Macro Avg	0.35	0.33	0.34	20
Weighted Avg	0.53	0.50	0.51	20

Super Smash Bros. Ultimate

Klasse	Precision	Recall	F1-Score	Support
0	0.60	0.55	0.57	11
1	0.00	0.00	0.00	2
2	0.20	0.33	0.25	3
3	0.33	0.33	0.33	3
4	0.78	0.78	0.78	9
Accuracy			**0.54**	**28**
Macro Avg	0.38	0.40	0.39	28
Weighted Avg	0.54	0.54	0.54	28

Animal Crossing: New Horizons

Klasse	Precision	Recall	F1-Score	Support
0	0.75	0.60	0.67	5
1	0.25	0.33	0.29	3
2	0.75	0.50	0.60	6
3	0.67	0.50	0.57	4
4	0.57	1.00	0.73	4
Accuracy			**0.59**	**22**
Macro Avg	0.60	0.59	0.57	22
Weighted Avg	0.63	0.59	0.59	22

Paper Mario: Sticker Star

Klasse	Precision	Recall	F1-Score	Support
0	1.00	0.67	0.80	6
1	0.50	1.00	0.67	2
2	0.67	1.00	0.80	4
3	0.62	0.62	0.62	8
4	0.50	0.25	0.33	4
Accuracy			**0.67**	**24**
Macro Avg	0.66	0.71	0.65	24
Weighted Avg	0.69	0.67	0.65	24

Nintendo Switch Sports

Klasse	Precision	Recall	F1-Score	Support
0	0.46	0.67	0.55	9
1	0.00	0.00	0.00	5
2	0.57	0.50	0.53	8
3	0.38	1.00	0.55	3
4	1.00	0.43	0.60	7
Accuracy			**0.50**	**32**
Macro Avg	0.48	0.52	0.44	32
Weighted Avg	0.53	0.50	0.47	32

The Legend of Zelda: Breath of the Wild

Klasse	Precision	Recall	F1-Score	Support
0	0.29	0.67	0.40	3
1	0.67	0.40	0.50	5
2	0.33	0.33	0.33	3
3	1.00	0.25	0.40	4
4	0.90	1.00	0.95	9
Accuracy			**0.62**	**24**
Macro Avg	0.64	0.53	0.52	24
Weighted Avg	0.72	0.62	0.62	24

Super Mario Party

Klasse	Precision	Recall	F1-Score	Support
0	0.67	1.00	0.80	4
1	1.00	0.50	0.67	4
2	0.50	0.40	0.44	5
3	0.33	0.50	0.40	4
4	0.50	0.40	0.44	5
Accuracy			**0.55**	**22**
Macro Avg	0.60	0.56	0.55	22
Weighted Avg	0.59	0.55	0.54	22

Mario Kart World

Klasse	Precision	Recall	F1-Score	Support
0	0.50	0.75	0.60	4
1	0.25	0.50	0.33	2
2	0.50	0.33	0.40	6
3	1.00	0.71	0.83	7
4	1.00	1.00	1.00	5

Accuracy			**0.67**	**24**
Macro Avg	0.65	0.66	0.63	24
Weighted Avg	0.73	0.67	0.68	24

Pokémon Legends: Z-A

Klasse	Precision	Recall	F1-Score	Support
0	0.71	1.00	0.83	5
1	0.33	0.50	0.40	2
2	1.00	0.25	0.40	4
3	0.67	0.40	0.50	5
4	0.50	0.75	0.60	4
Accuracy			**0.60**	**20**
Macro Avg	0.64	0.58	0.55	20
Weighted Avg	0.68	0.60	0.57	20

Pokémon Scarlet

Klasse	Precision	Recall	F1-Score	Support
0	0.71	1.00	0.83	5
1	0.00	0.00	0.00	1
2	0.00	0.00	0.00	4
3	0.60	0.38	0.46	8
4	0.67	1.00	0.80	6
Accuracy			**0.58**	**24**
Macro Avg	0.40	0.47	0.42	24
Weighted Avg	0.52	0.58	0.53	24

1.2 Mit Metadaten

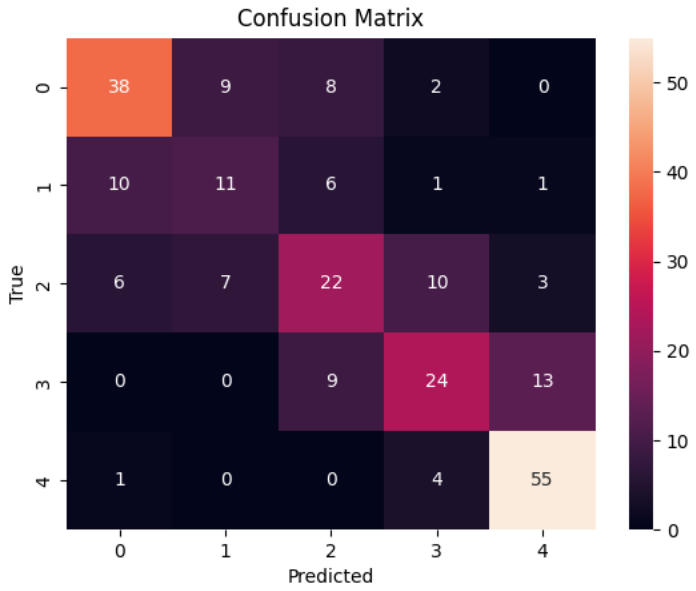

Vorhersageverteilung

Klasse	0	1	2	3	4	Gesamt
Anzahl	55	27	45	41	72	240

Gesamtergebnis

Klasse	Precision	Recall	F1-Score	Support
0	0.69	0.67	0.68	57
1	0.41	0.38	0.39	29
2	0.49	0.46	0.47	48
3	0.59	0.52	0.55	46
4	0.76	0.92	0.83	60
Accuracy			**0.62**	**240**
Macro Avg	0.59	0.59	0.59	240
Weighted Avg	0.61	0.62	0.62	240
MAE: *0.4875*				

Ergebnisse je Spiel

The Legend of Zelda: Tears of the Kingdom

Klasse	Precision	Recall	F1-Score	Support
0	0.62	1.00	0.77	5
1	1.00	0.33	0.50	3
2	1.00	0.20	0.33	5
3	0.00	0.00	0.00	0
4	1.00	0.86	0.92	7
Accuracy			**0.65**	**20**
Macro Avg	0.72	0.48	0.51	20
Weighted Avg	0.91	0.65	0.67	20

Super Smash Bros. Ultimate

Klasse	Precision	Recall	F1-Score	Support
0	0.75	0.55	0.63	11
1	0.50	0.50	0.50	2
2	0.00	0.00	0.00	3
3	0.50	0.33	0.40	3
4	0.82	1.00	0.90	9
Accuracy			**0.61**	**28**
Macro Avg	0.51	0.48	0.49	28
Weighted Avg	0.65	0.61	0.62	28

Animal Crossing: New Horizons

Klasse	Precision	Recall	F1-Score	Support
0	0.80	0.80	0.80	5
1	1.00	0.33	0.50	3
2	0.67	0.67	0.67	6
3	0.50	0.50	0.50	4
4	0.67	1.00	0.80	4
Accuracy			**0.68**	**22**
Macro Avg	0.73	0.66	0.65	22
Weighted Avg	0.71	0.68	0.67	22

Paper Mario: Sticker Star

Klasse	Precision	Recall	F1-Score	Support
0	1.00	0.67	0.80	6
1	0.67	1.00	0.80	2
2	0.43	0.75	0.55	4
3	0.75	0.38	0.50	8
4	0.67	1.00	0.80	4
Accuracy			**0.67**	**24**
Macro Avg	0.70	0.76	0.69	24
Weighted Avg	0.74	0.67	0.66	24

Nintendo Switch Sports

Klasse	Precision	Recall	F1-Score	Support
0	0.67	0.67	0.67	9
1	0.20	0.20	0.20	5
2	0.50	0.38	0.43	8
3	0.20	0.33	0.25	3
4	0.71	0.71	0.71	7
Accuracy			**0.50**	**32**
Macro Avg	0.46	0.46	0.45	32
Weighted Avg	0.52	0.50	0.51	32

The Legend of Zelda: Breath of the Wild

Klasse	Precision	Recall	F1-Score	Support
0	0.33	0.67	0.44	3
1	1.00	0.20	0.33	5
2	0.43	1.00	0.60	3
3	1.00	0.25	0.40	4
4	0.89	0.89	0.89	9
Accuracy			**0.62**	**24**
Macro Avg	0.73	0.60	0.53	24
Weighted Avg	0.80	0.62	0.60	24

Super Mario Party

Klasse	Precision	Recall	F1-Score	Support
0	1.00	0.50	0.67	4
1	0.60	0.75	0.67	4
2	0.50	0.40	0.44	5
3	0.33	0.50	0.40	4
4	0.80	0.80	0.80	5
Accuracy			**0.59**	**22**
Macro Avg	0.65	0.59	0.60	22
Weighted Avg	0.65	0.59	0.60	22

Mario Kart World

Klasse	Precision	Recall	F1-Score	Support
0	0.67	0.50	0.57	4
1	0.25	0.50	0.33	2
2	0.60	0.50	0.55	6
3	1.00	1.00	1.00	7
4	1.00	1.00	1.00	5
Accuracy			**0.75**	**24**
Macro Avg	0.70	0.70	0.69	24
Weighted Avg	0.78	0.75	0.76	24

Pokémon Legends: Z-A

Klasse	Precision	Recall	F1-Score	Support
0	0.60	0.60	0.60	5
1	0.00	0.00	0.00	2
2	1.00	0.75	0.86	4
3	1.00	0.40	0.57	5
4	0.57	1.00	0.73	4
Accuracy			**0.60**	**20**
Macro Avg	0.63	0.55	0.55	20
Weighted Avg	0.71	0.60	0.61	20

Pokémon Scarlet

Klasse	Precision	Recall	F1-Score	Support
0	0.80	0.80	0.80	5
1	0.00	0.00	0.00	1
2	0.00	0.00	0.00	4
3	0.83	0.62	0.71	8
4	0.60	1.00	0.75	6
Accuracy			**0.62**	**24**
Macro Avg	0.45	0.48	0.45	24
Weighted Avg	0.59	0.62	0.59	24

2. LLM

2.1 Ohne Metadaten

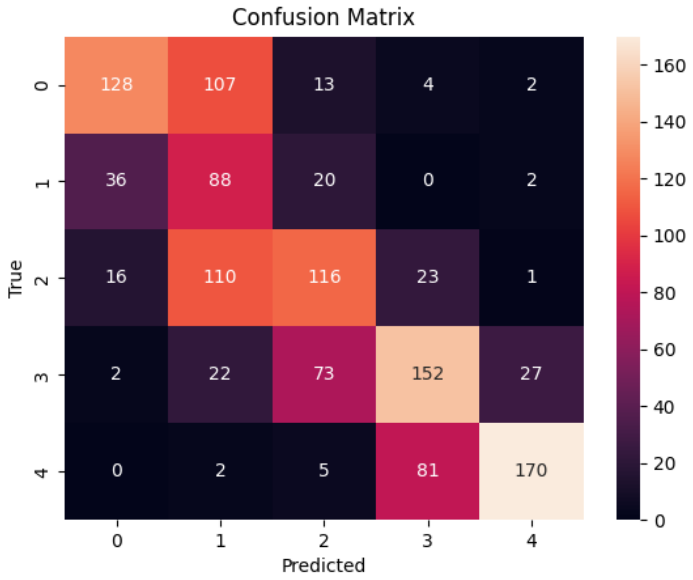

2.1.1 Normal (Zero-Shot)

Vorhersageverteilung (n=1200)

Klasse	0	1	2	3	4	Gesamt
Anzahl	182	329	227	260	202	1200

Majority Baseline

Klasse	Precision	Recall	F1-Score	Support
0	0.00	0.00	0.00	254
1	0.00	0.00	0.00	146
2	0.00	0.00	0.00	266
3	0.23	1.00	0.37	276
4	0.00	0.00	0.00	258
Accuracy			**0.23**	**1200**

Gesamtergebnis

Klasse	Precision	Recall	F1-Score	Support
0	0.70	0.50	0.59	254
1	0.27	0.60	0.37	146
2	0.51	0.44	0.47	266
3	0.58	0.55	0.57	276
4	0.84	0.66	0.74	258
Accuracy			**0.55**	**1200**
Macro Avg	0.58	0.55	0.55	1200
Weighted Avg	0.61	0.55	0.56	1200
MAE: *0.5242*				

Ergebnisse je Spiel

Mario Kart World

Klasse	Precision	Recall	F1-Score	Support
0	0.75	0.44	0.56	27
1	0.24	0.62	0.35	13
2	0.47	0.50	0.48	28
3	0.73	0.52	0.60	31
4	0.79	0.71	0.75	21
Accuracy			**0.54**	**120**
Macro Avg	0.60	0.56	0.55	120
Weighted Avg	0.63	0.54	0.56	120

Animal Crossing: New Horizons

Klasse	Precision	Recall	F1-Score	Support
0	0.72	0.52	0.60	25
1	0.25	0.53	0.34	15
2	0.45	0.47	0.46	19
3	0.72	0.50	0.59	36
4	0.80	0.80	0.80	25
Accuracy			**0.57**	**120**
Macro Avg	0.59	0.57	0.56	120
Weighted Avg	0.64	0.57	0.59	120

Pokémon Legends: Z-A

Klasse	Precision	Recall	F1-Score	Support
0	0.70	0.68	0.69	28
1	0.21	0.50	0.29	12
2	0.84	0.47	0.60	34
3	0.47	0.58	0.52	24
4	0.53	0.36	0.43	22
Accuracy			**0.53**	**120**
Macro Avg	0.55	0.52	0.51	120
Weighted Avg	0.61	0.53	0.54	120

Paper Mario: Sticker Star

Klasse	Precision	Recall	F1-Score	Support
0	0.80	0.74	0.77	27
1	0.29	0.62	0.39	13
2	0.54	0.52	0.53	29
3	0.63	0.61	0.62	31
4	0.89	0.40	0.55	20
Accuracy			**0.58**	**120**
Macro Avg	0.63	0.58	0.57	120
Weighted Avg	0.65	0.58	0.60	120

Nintendo Switch Sports

Klasse	Precision	Recall	F1-Score	Support
0	0.76	0.48	0.59	27
1	0.16	0.38	0.22	13
2	0.42	0.41	0.42	27
3	0.53	0.67	0.59	27
4	0.91	0.38	0.54	26
Accuracy			**0.47**	**120**
Macro Avg	0.56	0.46	0.47	120
Weighted Avg	0.60	0.47	0.50	120

The Legend of Zelda: Tears of the Kingdom

Klasse	Precision	Recall	F1-Score	Support
0	0.55	0.27	0.36	22
1	0.30	0.72	0.43	18
2	0.41	0.29	0.34	24
3	0.41	0.47	0.44	19
4	1.00	0.73	0.84	37
Accuracy			**0.52**	**120**
Macro Avg	0.53	0.50	0.48	120
Weighted Avg	0.60	0.52	0.53	120

Super Smash Bros. Ultimate

Klasse	Precision	Recall	F1-Score	Support
0	0.79	0.38	0.51	29
1	0.19	0.64	0.30	11
2	0.53	0.39	0.45	23
3	0.60	0.60	0.60	25
4	0.89	0.78	0.83	32
Accuracy			**0.56**	**120**
Macro Avg	0.60	0.56	0.54	120
Weighted Avg	0.67	0.56	0.58	120

The Legend of Zelda: Breath of the Wild

Klasse	Precision	Recall	F1-Score	Support
0	0.58	0.33	0.42	21
1	0.30	0.68	0.42	19
2	0.24	0.15	0.19	26
3	0.50	0.24	0.32	17
4	0.93	1.00	0.96	37
Accuracy			**0.54**	**120**
Macro Avg	0.51	0.48	0.46	120
Weighted Avg	0.56	0.54	0.52	120

Pokémon Scarlet

Klasse	Precision	Recall	F1-Score	Support
0	0.57	0.67	0.62	24
1	0.33	0.56	0.42	16
2	0.55	0.38	0.45	29
3	0.60	0.55	0.57	33
4	0.73	0.61	0.67	18
Accuracy			**0.54**	**120**
Macro Avg	0.56	0.55	0.54	120
Weighted Avg	0.57	0.54	0.54	120

Super Mario Party

Klasse	Precision	Recall	F1-Score	Support
0	0.79	0.46	0.58	24
1	0.42	0.69	0.52	16
2	0.61	0.74	0.67	27
3	0.62	0.64	0.63	33
4	0.69	0.45	0.55	20
Accuracy			**0.60**	**120**
Macro Avg	0.62	0.59	0.59	120
Weighted Avg	0.64	0.60	0.60	120

2.1.2 Few-Shot

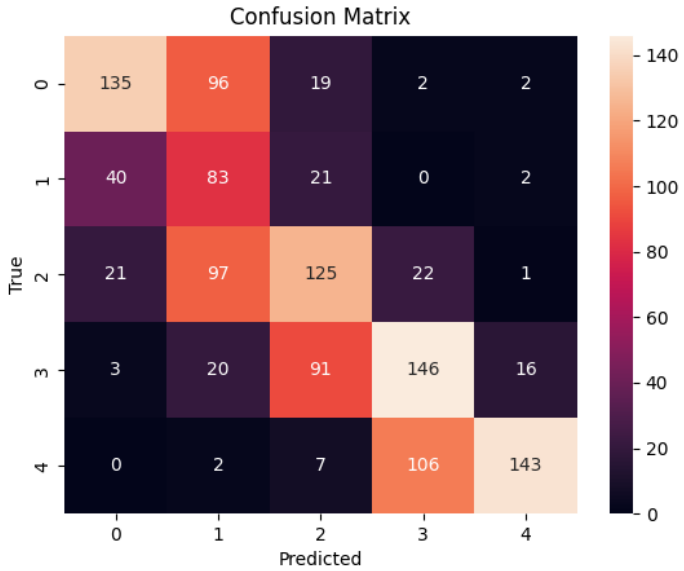

Vorhersageverteilung (n=1200)

Klasse	0	1	2	3	4	Gesamt
Anzahl	199	298	263	276	164	1200

Gesamtergebnis

Klasse	Precision	Recall	F1-Score	Support
0	0.68	0.53	0.60	254
1	0.28	0.57	0.37	146
2	0.48	0.47	0.47	266
3	0.53	0.53	0.53	276
4	0.87	0.55	0.68	258
Accuracy			**0.53**	**1200**
Macro Avg	0.57	0.53	0.53	1200
Weighted Avg	0.59	0.53	0.54	1200
MAE: *0.55*				

2.1.2 Few-Shot – Ergebnisse je Spiel

Mario Kart World

Klasse	Precision	Recall	F1-Score	Support
0	0.69	0.41	0.51	27
1	0.27	0.62	0.37	13
2	0.49	0.61	0.54	28
3	0.64	0.52	0.57	31
4	0.86	0.57	0.69	21
Accuracy			0.53	120
Macro Avg	0.59	0.54	0.54	120
Weighted Avg	0.61	0.53	0.55	120

Animal Crossing: New Horizons

Klasse	Precision	Recall	F1-Score	Support
0	0.65	0.52	0.58	25
1	0.28	0.47	0.35	15
2	0.40	0.53	0.45	19
3	0.63	0.53	0.58	36
4	0.90	0.72	0.80	25
Accuracy			0.56	120
Macro Avg	0.57	0.55	0.55	120
Weighted Avg	0.61	0.56	0.58	120

Pokémon Legends: Z-A

Klasse	Precision	Recall	F1-Score	Support
0	0.73	0.79	0.76	28
1	0.21	0.42	0.28	12
2	0.71	0.50	0.59	34
3	0.52	0.71	0.60	24
4	0.67	0.27	0.39	22
Accuracy			0.56	120
Macro Avg	0.57	0.54	0.52	120
Weighted Avg	0.62	0.56	0.56	120

Paper Mario: Sticker Star

Klasse	Precision	Recall	F1-Score	Support
0	0.74	0.74	0.74	27
1	0.35	0.69	0.46	13
2	0.48	0.55	0.52	29
3	0.52	0.45	0.48	31
4	0.86	0.30	0.44	20

Accuracy			0.54	120
Macro Avg	0.59	0.55	0.53	120
Weighted Avg	0.60	0.54	0.54	120

Nintendo Switch Sports

Klasse	Precision	Recall	F1-Score	Support
0	0.72	0.48	0.58	27
1	0.17	0.46	0.25	13
2	0.39	0.33	0.36	27
3	0.45	0.63	0.52	27
4	0.83	0.19	0.31	26
Accuracy			0.42	120
Macro Avg	0.51	0.42	0.40	120
Weighted Avg	0.55	0.42	0.42	120

The Legend of Zelda: Tears of the Kingdom

Klasse	Precision	Recall	F1-Score	Support
0	0.62	0.36	0.46	22
1	0.31	0.67	0.42	18
2	0.38	0.33	0.36	24
3	0.35	0.42	0.38	19
4	1.00	0.65	0.79	37
Accuracy			0.50	120
Macro Avg	0.53	0.49	0.48	120
Weighted Avg	0.60	0.50	0.52	120

Super Smash Bros. Ultimate

Klasse	Precision	Recall	F1-Score	Support
0	0.80	0.41	0.55	29
1	0.19	0.55	0.29	11
2	0.45	0.43	0.44	23
3	0.50	0.52	0.51	25
4	0.85	0.69	0.76	32
Accuracy			0.53	120
Macro Avg	0.56	0.52	0.51	120
Weighted Avg	0.63	0.53	0.55	120

The Legend of Zelda: Breath of the Wild

Klasse	Precision	Recall	F1-Score	Support
0	0.59	0.48	0.53	21
1	0.29	0.53	0.37	19
2	0.32	0.27	0.29	26
3	0.44	0.24	0.31	17
4	0.95	0.95	0.95	37
Accuracy			0.55	120
Macro Avg	0.52	0.49	0.49	120
Weighted Avg	0.57	0.55	0.55	120

Pokémon Scarlet

Klasse	Precision	Recall	F1-Score	Support
0	0.55	0.67	0.60	24
1	0.37	0.62	0.47	16
2	0.52	0.38	0.44	29
3	0.56	0.55	0.55	33
4	0.64	0.39	0.48	18
Accuracy			0.52	120
Macro Avg	0.53	0.52	0.51	120
Weighted Avg	0.54	0.52	0.51	120

Super Mario Party

Klasse	Precision	Recall	F1-Score	Support
0	0.71	0.42	0.53	24
1	0.38	0.62	0.48	16
2	0.54	0.74	0.62	27
3	0.61	0.61	0.61	33
4	0.80	0.40	0.53	20
Accuracy			0.57	120
Macro Avg	0.61	0.56	0.55	120
Weighted Avg	**0.62**	**0.57**	**0.56**	**120**

2.1.3 Verschiedene Datensatzgrößen – Ohne Metadaten (Zero-Shot)

Größe: 200

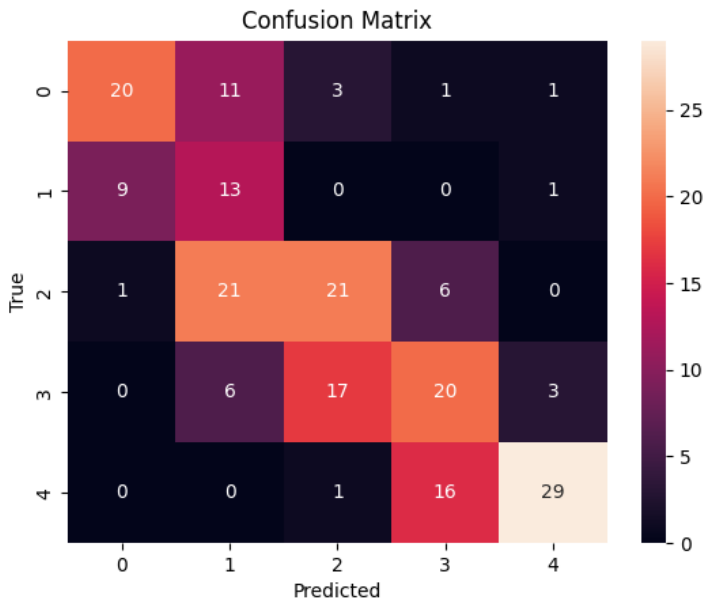

Vorhersageverteilung

Klasse	0	1	2	3	4	Gesamt
Anzahl	**29**	**51**	**40**	**46**	**34**	**200**

Gesamtergebnis

Klasse	Precision	Recall	F1-Score	Support
0	0.66	0.53	0.58	36
1	0.25	0.57	0.35	23
2	0.53	0.43	0.47	49
3	0.50	0.50	0.50	46
4	0.85	0.63	0.72	46
Accuracy			0.53	200
Macro Avg	0.56	0.53	0.53	200
Weighted Avg	0.59	0.53	0.54	200
MAE: 0.56				

Majority Baseline

Klasse	Precision	Recall	F1-Score	Support
2	0.24	1.00	0.39	49
Accuracy			0.24	200

Größe: 500

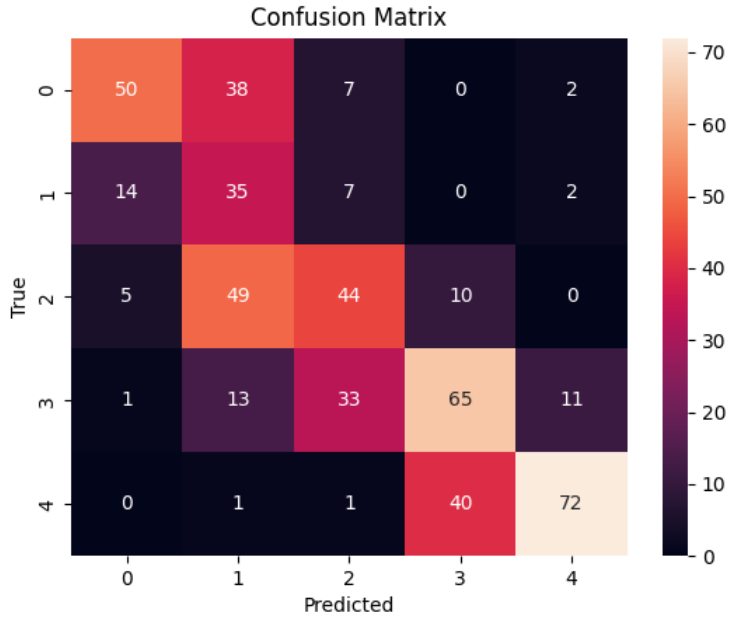

Vorhersageverteilung

Klasse	0	1	2	3	4	Gesamt
Anzahl	70	136	92	115	87	500

Gesamtergebnis

Klasse	Precision	Recall	F1-Score	Support
0	0.71	0.52	0.60	97
1	0.26	0.60	0.36	58
2	0.48	0.41	0.44	108
3	0.57	0.53	0.55	123
4	0.83	0.63	0.72	114
Accuracy			0.53	500
Macro Avg	0.57	0.54	0.53	500
Weighted Avg	0.60	0.53	0.55	500
MAE: 0.548				

Majority Baseline

Klasse	Precision	Recall	F1-Score	Support
3	0.25	1.00	0.39	123
Accuracy			0.25	500

Größe: 800

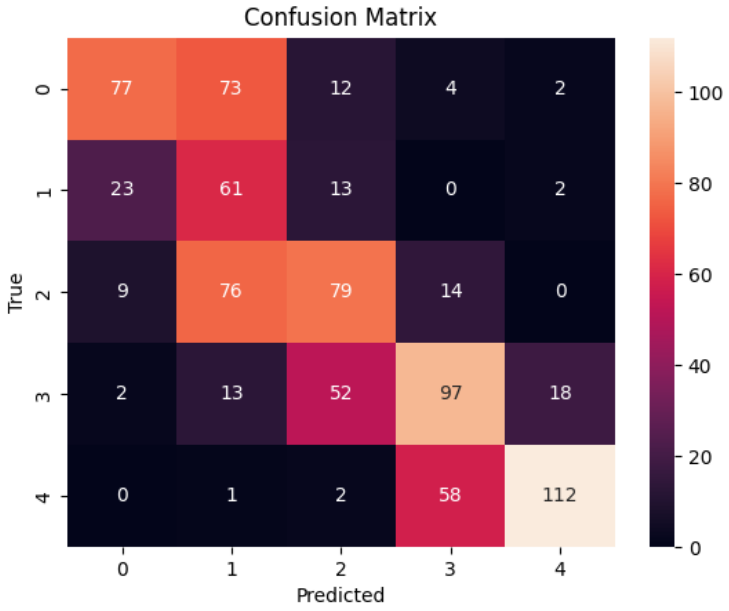

Vorhersageverteilung

Klasse	0	1	2	3	4	Gesamt
Anzahl	111	224	158	173	134	800

Gesamtergebnis

Klasse	Precision	Recall	F1-Score	Support
0	0.69	0.46	0.55	168
1	0.27	0.62	0.38	99
2	0.50	0.44	0.47	178
3	0.56	0.53	0.55	182
4	0.84	0.65	0.73	173
Accuracy			0.53	800
Macro Avg	0.57	0.54	0.54	800
Weighted Avg	0.60	0.53	0.55	800

Majority Baseline

Klasse	Precision	Recall	F1-Score	Support
3	0.23	1.00	0.37	182
Accuracy			0.23	800

2.2 Mit Metadaten

2.2.1 Normal (Zero-Shot)

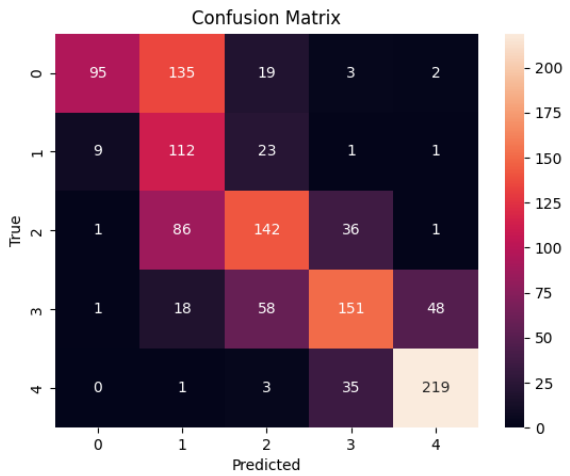

Vorhersageverteilung (n=1200)

Klasse	0	1	2	3	4	Gesamt
Anzahl	**106**	**352**	**245**	**226**	**271**	**1200**

Gesamtergebnis

Klasse	Precision	Recall	F1-Score	Support
0	0.90	0.37	0.53	254
1	0.32	0.77	0.45	146
2	0.58	0.53	0.56	266
3	0.67	0.55	0.60	276
4	0.81	0.85	0.83	258
Accuracy			0.60	1200
Macro Avg	0.65	0.61	0.59	1200
Weighted Avg	0.68	0.60	0.61	1200
MAE: 0.4517				

Ergebnisse je Spiel

Mario Kart World

Klasse	Precision	Recall	F1-Score	Support
0	1.00	0.30	0.46	27
1	0.32	0.92	0.47	13
2	0.61	0.61	0.61	28
3	0.82	0.58	0.68	31
4	0.75	0.86	0.80	21
Accuracy			0.61	120
Macro Avg	0.70	0.65	0.60	120
Weighted Avg	0.74	0.61	0.61	120

Animal Crossing: New Horizons

Klasse	Precision	Recall	F1-Score	Support
0	0.92	0.44	0.59	25
1	0.33	0.67	0.44	15
2	0.50	0.68	0.58	19
3	0.72	0.50	0.59	36
4	0.78	0.84	0.81	25
Accuracy			0.61	120
Macro Avg	0.65	0.63	0.60	120
Weighted Avg	0.69	0.61	0.62	120

Pokémon Legends: Z-A

Klasse	Precision	Recall	F1-Score	Support
0	0.93	0.46	0.62	28
1	0.25	0.75	0.38	12
2	0.73	0.47	0.57	34
3	0.58	0.46	0.51	24
4	0.66	0.86	0.75	22
Accuracy			0.57	120
Macro Avg	0.63	0.60	0.56	120
Weighted Avg	0.68	0.57	0.58	120

Paper Mario: Sticker Star

Klasse	Precision	Recall	F1-Score	Support
0	0.90	0.33	0.49	27
1	0.25	0.77	0.38	13
2	0.62	0.55	0.58	29
3	0.68	0.55	0.61	31
4	0.74	0.70	0.72	20
Accuracy			0.55	120
Macro Avg	0.64	0.58	0.55	120
Weighted Avg	0.68	0.55	0.57	120

Nintendo Switch Sports

Klasse	Precision	Recall	F1-Score	Support
0	1.00	0.37	0.54	27
1	0.29	0.77	0.42	13
2	0.52	0.48	0.50	27
3	0.64	0.59	0.62	27
4	0.80	0.77	0.78	26
Accuracy			0.57	120
Macro Avg	0.65	0.60	0.57	120
Weighted Avg	0.69	0.57	0.59	120

The Legend of Zelda: Tears of the Kingdom

Klasse	Precision	Recall	F1-Score	Support
0	0.86	0.27	0.41	22
1	0.38	0.83	0.53	18
2	0.48	0.46	0.47	24
3	0.56	0.53	0.54	19
4	0.97	0.86	0.91	37
Accuracy			0.62	120
Macro Avg	0.65	0.59	0.57	120
Weighted Avg	0.70	0.62	0.62	120

Super Smash Bros. Ultimate

Klasse	Precision	Recall	F1-Score	Support
0	0.91	0.34	0.50	29
1	0.23	0.64	0.34	11
2	0.64	0.70	0.67	23
3	0.81	0.68	0.74	25
4	0.91	0.94	0.92	32
Accuracy			0.67	120
Macro Avg	0.70	0.66	0.63	120
Weighted Avg	0.77	0.67	0.68	120

The Legend of Zelda: Breath of the Wild

Klasse	Precision	Recall	F1-Score	Support
0	**1.00**	**0.14**	**0.25**	**21**
1	0.40	0.95	0.56	19
2	0.68	0.58	0.62	26
3	0.82	0.53	0.64	17
4	0.95	1.00	0.97	37
Accuracy			0.68	120
Macro Avg	0.77	0.64	0.61	120
Weighted Avg	0.79	0.68	0.66	120

Pokémon Scarlet

Klasse	Precision	Recall	F1-Score	Support
0	0.78	0.58	0.67	24
1	0.33	0.69	0.45	16
2	0.50	0.38	0.43	29
3	0.62	0.45	0.53	33
4	0.65	0.83	0.73	18
Accuracy			0.55	120
Macro Avg	0.58	0.59	0.56	120
Weighted Avg	0.59	0.55	0.55	120

Super Mario Party

Klasse	Precision	Recall	F1-Score	Support
0	0.85	0.46	0.59	24
1	0.38	0.62	0.48	16
2	0.54	0.52	0.53	27
3	0.56	0.61	0.58	33
4	0.68	0.65	0.67	20
Accuracy			0.57	120
Macro Avg	0.60	0.57	0.57	120
Weighted Avg	0.61	0.57	0.57	120

2.2.2 Few-Shot - Ergebnisse je Spiel

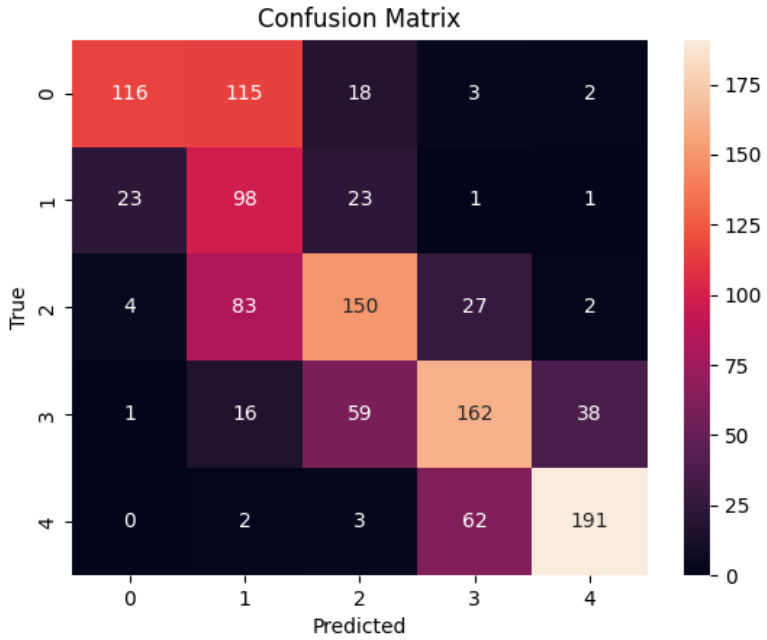

Vorhersageverteilung (n=1200)

Klasse	0	1	2	3	4	Gesamt
Anzahl	144	314	253	255	234	1200

Gesamtergebnis

Klasse	Precision	Recall	F1-Score	Support
0	0.81	0.46	0.58	254
1	0.31	0.67	0.43	146
2	0.59	0.56	0.58	266
3	0.64	0.59	0.61	276
4	0.82	0.74	0.78	258
Accuracy			0.60	1200
Macro Avg	0.63	0.60	0.59	1200
Weighted Avg	0.66	0.60	0.61	1200
MAE: 0.4558				

Mario Kart World

Klasse	Precision	Recall	F1-Score	Support
0	1.00	0.30	0.46	27
1	0.31	0.92	0.46	13
2	0.71	0.71	0.71	28
3	0.83	0.65	0.73	31
4	0.76	0.76	0.76	21
Accuracy			0.63	120
Macro Avg	0.72	0.67	0.62	120
Weighted Avg	0.77	0.63	0.64	120

Animal Crossing: New Horizons

Klasse	Precision	Recall	F1-Score	Support
0	0.81	0.52	0.63	25
1	0.32	0.53	0.40	15
2	0.46	0.58	0.51	19
3	0.58	0.53	0.55	36
4	0.77	0.68	0.72	25
Accuracy			0.57	120
Macro Avg	0.59	0.57	0.56	120
Weighted Avg	0.62	0.57	0.58	120

Pokémon Legends: Z-A

Klasse	Precision	Recall	F1-Score	Support
0	0.82	0.64	0.72	28
1	0.22	0.50	0.31	12
2	0.78	0.62	0.69	34
3	0.55	0.46	0.50	24
4	0.58	0.64	0.61	22
Accuracy			0.58	120
Macro Avg	0.59	0.57	0.56	120
Weighted Avg	0.65	0.58	0.61	120

Paper Mario: Sticker Star

Klasse	Precision	Recall	F1-Score	Support
0	0.84	0.59	0.70	27
1	0.29	0.62	0.39	13
2	0.60	0.62	0.61	29
3	0.70	0.61	0.66	31
4	0.81	0.65	0.72	20
Accuracy			0.62	120
Macro Avg	0.65	0.62	0.61	120
Weighted Avg	0.68	0.62	0.64	120

Nintendo Switch Sports

Klasse	Precision	Recall	F1-Score	Support
0	1.00	0.44	0.62	27
1	0.26	0.77	0.39	13
2	0.55	0.41	0.47	27
3	0.55	0.63	0.59	27
4	0.74	0.54	0.62	26
Accuracy			0.53	120
Macro Avg	0.62	0.56	0.54	120
Weighted Avg	0.66	0.53	0.55	120

The Legend of Zelda: Tears of the Kingdom

Klasse	Precision	Recall	F1-Score	Support
0	0.67	0.36	0.47	22
1	0.39	0.72	0.51	18
2	0.46	0.50	0.48	24
3	0.50	0.47	0.49	19
4	1.00	0.84	0.91	37
Accuracy			0.61	120
Macro Avg	0.60	0.58	0.57	120
Weighted Avg	0.66	0.61	0.62	120

Super Smash Bros. Ultimate

Klasse	Precision	Recall	F1-Score	Support
0	0.85	0.38	0.52	29
1	0.20	0.55	0.29	11
2	0.62	0.70	0.65	23
3	0.76	0.64	0.70	25
4	0.90	0.84	0.87	32
Accuracy			0.63	120
Macro Avg	0.66	0.62	0.61	120
Weighted Avg	0.74	0.63	0.66	120

The Legend of Zelda: Breath of the Wild

Klasse	Precision	Recall	F1-Score	Support
0	0.83	0.24	0.37	21
1	0.38	0.84	0.52	19
2	0.57	0.50	0.53	26
3	0.82	0.53	0.64	17
4	0.95	0.97	0.96	37
Accuracy			0.66	120
Macro Avg	0.71	0.62	0.61	120
Weighted Avg	0.74	0.66	0.65	120

Pokémon Scarlet

Klasse	Precision	Recall	F1-Score	Support
0	0.65	0.71	0.68	24
1	0.35	0.56	0.43	16
2	0.61	0.38	0.47	29
3	0.62	0.55	0.58	33
4	0.62	0.72	0.67	18
Accuracy			0.57	120
Macro Avg	0.57	0.58	0.56	120
Weighted Avg	0.59	0.57	0.57	120

Super Mario Party

Klasse	Precision	Recall	F1-Score	Support
0	0.80	0.33	0.47	24
1	0.38	0.62	0.48	16
2	0.55	0.63	0.59	27
3	0.59	0.73	0.65	33
4	0.83	0.50	0.62	20
Accuracy			0.57	120
Macro Avg	0.63	0.56	0.56	120
Weighted Avg	0.63	0.57	0.57	120

2.2.3 Verschiedene Datensatzgrößen – Mit Metadaten (Zero-Shot)

Größe: 200

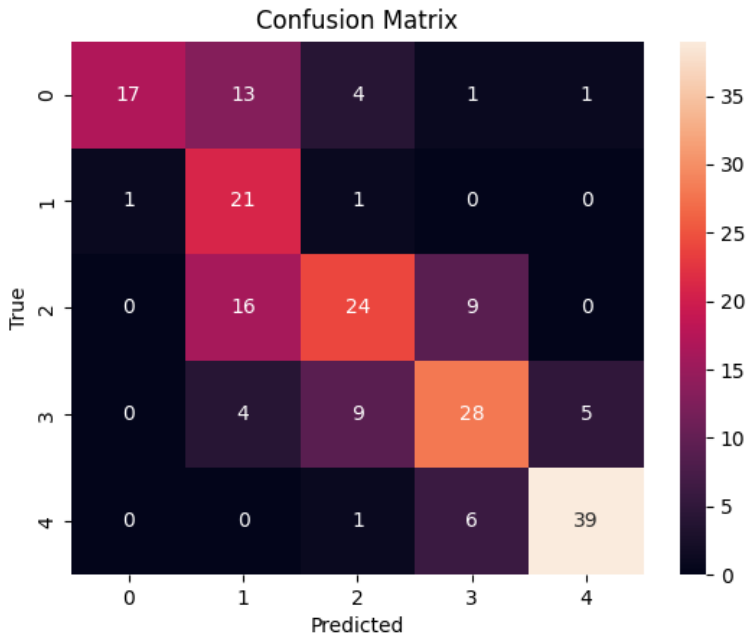

Klasse	0	1	2	3	4	Gesamt
Anzahl	**18**	**54**	**39**	**44**	**45**	**200**

Gesamtergebnis

Klasse	Precision	Recall	F1-Score	Support
0	0.94	0.47	0.63	36
1	0.39	0.91	0.55	23
2	0.62	0.49	0.55	49
3	0.64	0.61	0.62	46
4	0.87	0.85	0.86	46
Accuracy			0.65	200
Macro Avg	0.69	0.67	0.64	200
Weighted Avg	0.71	0.65	0.65	200
MAE: 0.425				

Größe: 500

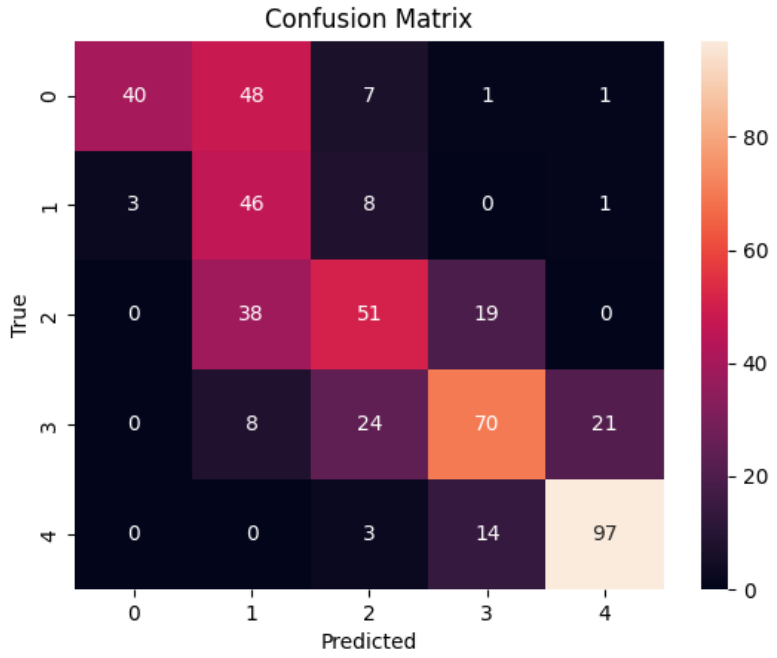

Vorhersageverteilung

Klasse	0	1	2	3	4	Gesamt
Anzahl	43	140	93	104	120	500

Gesamtergebnis

Klasse	Precision	Recall	F1-Score	Support
0	0.93	0.41	0.57	97
1	0.33	0.79	0.46	58
2	0.55	0.47	0.51	108
3	0.67	0.57	0.62	123
4	0.81	0.85	0.83	114
Accuracy			0.61	500
Macro Avg	0.66	0.62	0.60	500
Weighted Avg	0.69	0.61	0.62	500
MAE: 0.442				

Größe: 800

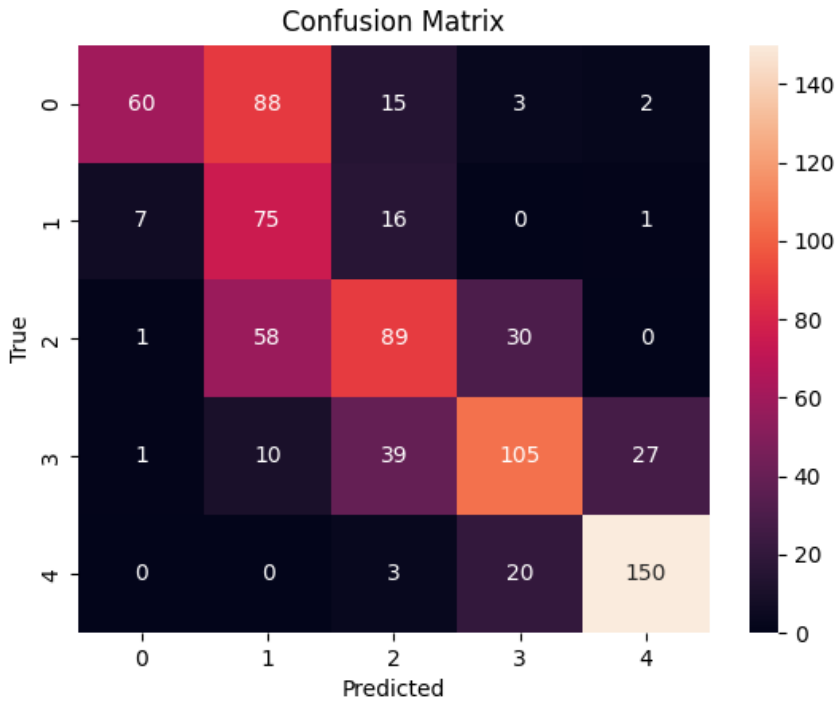

Vorhersageverteilung

Klasse	0	1	2	3	4	Gesamt
Anzahl	69	231	162	158	180	800

Gesamtergebnis

Klasse	Precision	Recall	F1-Score	Support
0	0.87	0.36	0.51	168
1	0.32	0.76	0.45	99
2	0.55	0.50	0.52	178
3	0.66	0.58	0.62	182
4	0.83	0.87	0.85	173
Accuracy			0.60	800
Macro Avg	0.65	0.61	0.59	800
Weighted Avg	0.68	0.60	0.60	800
MAE: 0.4575				